

Coplilot

开发手册

Lao Chen

2026 年 8 月 17 日

目录

前言	1
1 LLM 与 Transformer 概述	2
1.1 从神经语言模型到 Transformer	2
1.2 Transformer 架构	2
1.3 预训练时代: BERT、GPT、T5	3
1.4 规模化定律	4
1.5 对齐: RLHF 与指令微调	5
1.6 代码生成 LLM	6
1.7 Agent 范式	6
1.8 孔洞驱动开发 (Hole-driven Development)	7
1.9 语义空间缩减率的形式化	8
2 复盘: CodeBuddy 原生实践中的 LLM Agent 失控	10
2.1 为什么要复盘?	10
2.2 五大典型事故	10
2.2.1 走错项目 (2026-06-29 21:15)	10

2.2.2	产线宕机: develop 白名单误匹配 (2026-06-29 19:35)	11
2.2.3	SSH 死锁: 基于虚假信息诊断 (2026-06-28 22:00)	11
2.2.4	PID 误杀 (2026-06-29 多次)	12
2.2.5	提示词优化的天花板 (2026-06-29 全天)	12
2.3	根因归纳	12
2.4	L4 拦截器深度加固: 幂等性守卫与行为影子化	13
2.4.1	命令白名单与幂等性校验	13
2.4.2	行为影子化 (Shadowing)	13
3	架构约束	15
3.1	为什么要讨论架构?	15
3.2	全栈架构概览	15
3.3	核心架构理念 —— RPC as Functor	16
3.4	架构对 AI 编程的约束	16
3.5	LLM 代码生成的现状与局限	17
4	编译器 (含类型系统) 约束	18
4.1	编译器不是第二大脑	18
4.2	类型系统是自然语言的离散化	19
4.3	类型约束注入	20
4.3.1	类型信息的提取	20
4.3.2	注入到提示词	20
4.3.3	类型推断的作用	21
4.4	编译器反馈循环	21

4.4.1	基本流程	21
4.4.2	LLM 欠缺的形式化能力	22
4.4.3	命名约定作为类型约束的延伸	22
4.5	效果评估	22
4.6	FCS 深度集成——从编译器到代码修复器	22
4.6.1	实时 AST 重写	23
4.6.2	GetSemanticClassification 强推入——以 FS0041 为例	23
5	JCS 与自动生成代码的保护约束	25
5.1	JCS 的理论基础	25
5.1.1	JCS 是严格的确定性知识描述映射	25
5.2	TypeSys 代码生成流水线	26
5.3	生成代码禁止手动修改	26
5.3.1	正确的修改流程	27
5.4	LLM 与 JCS 的对比：确定性 vs 模糊性	27
5.5	JCS 对 Copilot 的启示	28
5.6	只读文件系统钩子与增量式单向同步	28
5.6.1	只读 VFS 钩子（Read-Only VFS Hook）	28
5.6.2	增量式单向同步（Incremental One-Way Sync）	29
6	Copilot 的设计规范	30
6.1	设计目标	30
6.2	提示词优化的天花板——来自 Dev Skill 的实践	30
6.3	五层拦截器架构	31

6.4	为什么需要比 MCP 更强的约束?	32
6.5	Agent SDK 的中止与拦截对比	33
6.6	设计规范要点	33
6.7	设计哲学	33
7	技术实施方案	35
7.1	开发语言方案研讨	35
7.1.1	F#: 首选方案——全层原生适配	35
7.1.2	TypeScript: 次选方案——前端层原生、核心层受限	36
7.1.3	Python: 备选方案——仅适用于快速原型	37
7.1.4	方案对比与推荐	37
7.2	AIO Avalonia 现有界面分析	38
7.2.1	现有架构	39
7.2.2	现存的问题	40
7.3	Copilot 界面嵌入设计	40
7.3.1	整体策略	41
7.3.2	新布局设计	41
7.3.3	界面效果预览	42
7.3.4	布局详细规格	44
7.3.5	新增 UI 组件	44
7.3.6	F# 代码实现方案	45
7.3.7	与现有代码的集成点	46
7.3.8	从静态日志到动态时光机 (Timeline Shift)	46

7.3.9 树状分支图控件 (Tree Graph Control)	47
7.3.10 UI 扩展对架构的影响	48
7.4 临时文件管理	48
7.5 错误信息提取	49
7.6 反馈提示词设计	49
7.7 完整执行流程	49
7.8 模型选择策略	49
7.9 权限白名单体系	50
7.10 实施路线图	50
8 类型论	52
8.0.1 从简单类型到依赖类型	52
8.0.2 国内类型论研究的四层金字塔	53
8.0.3 工程师为什么要学依赖类型论?	53
8.0.4 依赖类型论在本项目中的映射	54
9 前沿研究与系统演进	56
9.1 MCP 够不够——从静态协议到全状态守卫网关	56
9.1.1 MCP 的贡献: 连接性与语义对齐	57
9.1.2 局限性: 静态性	57
9.1.3 演进方向: 全状态守卫网关 (Stateful Guardrails)	57
9.2 反馈循环的进阶——从线性反思到 MCTS 搜索树	58
9.2.1 当前 Loop 的天花板	58
9.2.2 前沿方案: MCTS 代码生成	58

9.2.3	工程实现路径	59
9.2.4	确定性奖励函数 (Deterministic Reward Function)	59
9.3	多 Agent 竞争与协同	61
9.3.1	单一 Agent 的失效模式	61
9.3.2	方案 A: 红蓝对抗 (Competitive Red-Teaming)	61
9.3.3	方案 B: 多视角共识 (Multi-Perspective Consensus)	61
9.3.4	工程考量	62
9.3.5	红蓝对抗的靶场化 (Sandboxed Range)	62
9.4	神经符号系统——代码语义的图嵌入与形式化验证	64
9.4.1	代码语义的图嵌入化 (Graph-Based Grounding)	64
9.4.2	符号约束求解——SMT Solver 介入	65
9.4.3	工程现实与渐进路径	65
9.5	系统演进战略总图	66
	总结	68
	参考文献	70

前言

本手册记录 AI 辅助编程系统 Copilot 的设计思路与实践经验。核心问题是：
大语言模型（LLM）在代码生成中的系统性缺陷如何被约束？

- LLM 生成的代码不可靠——语法错误、类型错误、逻辑错误、幻觉 API [M. Chen, Tworek, Jun, et al., 2021]
- 原生 Agent（CodeBuddy）在真实项目中暴露出五类典型事故——走错项目、端口误配、虚假信息信任、PID 误杀、规则膨胀
- 提示词工程有无法逾越的天花板 [Liu, Lin, Hewitt, et al., 2023]——必须引入编译器、类型系统、权限控制等**外部约束**

本手册分为七章：

1. LLM 与 Transformer——从统计语言模型到大语言模型的理论脉络
2. 复盘——CodeBuddy 原生实践中的 LLM Agent 失控
3. 架构约束——全栈架构如何缩减 LLM 的可能输出空间
4. 编译器约束——类型系统是自然语言的形式化离散化
5. JCS 保护约束——确定性代码生成的边界
6. Copilot 设计规范——五层拦截器架构
7. 技术实施方案——开发语言选型、AIO 界面嵌入、部署路线

第 1 章

LLM 与 Transformer 概述

第 1.1 节 从神经语言模型到 Transformer

大语言模型（LLM）的本质是统计语言模型：给定前文，预测下一个 token 的条件概率分布。其理论基础可追溯到 Bengio 等提出的神经概率语言模型 [Bengio et al., 2003]——用多层感知机学习词的分布式表示（word embedding），将离散的词汇映射到连续的向量空间中 [Mikolov et al., 2013]。

在此之后的十年间，序列建模的主流架构是循环神经网络（RNN）及其变体：LSTM [Hochreiter and Schmidhuber, 1997] 用门控机制缓解梯度消失，GRU [Cho, Merriënboer, Gulcehre, et al., 2014] 简化为更新门+重置门。Seq2Seq 框架 [Sutskever, Vinyals, and Le, 2014] 引入编码器-解码器结构，Bahdanau 等进一步提出注意力机制 [Bahdanau, Cho, and Bengio, 2015]——让解码器在生成每个输出时动态地关注编码器的不同位置，这是 Transformer 架构中自注意力机制的直接前身。

第 1.2 节 Transformer 架构

Vaswani 等在 2017 年提出 Transformer 架构 [Vaswani, Shazeer, Parmar, et al., 2017]，彻底抛弃了循环结构，代之以自注意力机制（Self-Attention）：

定义 1.2.1 (缩放点积注意力). 给定查询 Q 、键 K 、值 V ,

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

其中 d_k 是键向量的维度, 除以 $\sqrt{d_k}$ 防止内积过大导致 softmax 梯度消失。

Transformer 的核心创新:

1. **多头注意力 (Multi-Head Attention)**: 并行运行 h 个注意力头, 每个头在不同的投影子空间中学习不同的关联模式 [Vaswani, Shazeer, Parmar, et al., 2017]
2. **位置编码 (Positional Encoding)**: 由于没有循环结构, Transformer 通过正弦/余弦函数或可学习的位置嵌入注入序列顺序信息。
3. **残差连接 + 层归一化**: 每个子层 (自注意力/前馈网络) 的输出都经过残差连接和层归一化, 保证深层网络的可训练性 [Vaswani, Shazeer, Parmar, et al., 2017]。
4. **编码器-解码器 vs 解码器仅**: 原始 Transformer 使用编码器-解码器结构; 但 GPT 系列 [Radford, Narasimhan, et al., 2018; Radford, Jeffrey Wu, Child, et al., 2019; Brown, Mann, Ryder, et al., 2020] 仅使用解码器 (单向自注意力), 在自回归语言建模 (预测下一个 token) 上效果更好。

自注意力机制的复杂度为 $O(n^2 \cdot d)$ (n 是序列长度, d 是维度), 这是 Transformer 的核心计算瓶颈。后续工作如 Transformer-XL [Dai, Z. Yang, Y. Yang, et al., 2019] 引入段级递归和相对位置编码, 突破了固定上下文长度的限制。

第 1.3 节 预训练时代: BERT、GPT、T5

2018–2020 年, 预训练-微调 (Pre-train + Fine-tune) 范式彻底改变了 NLP:

- **GPT (自回归语言模型)**: Radford 等 [Radford, Narasimhan, et al., 2018] 提出生成式预训练——在大量无标注文本上训练一个单向 Transformer 解码器, 预测下一个 token; 然后在下游任务上微调。GPT-2 [Radford, Jeffrey Wu, Child, et al., 2019] 证明, 仅用语言建模目标训练的 1.5B 参数模型即可在多个 NLP 任务上实现 zero-shot

迁移

- **BERT（自编码语言模型）**：Devlin 等 [Devlin et al., 2019] 提出掩码语言模型（MLM）——随机遮蔽 15% 的输入 token，让模型从双向上下文中预测被遮蔽的词。配合下一句预测（NSP）任务，BERT 在 11 项 NLP 基准上刷新了记录。**关键区别**：GPT 单向 → 适合生成；BERT 双向 → 适合理解
- **T5（统一框架）**：Raffel 等 [Raffel, Shazeer, Roberts, et al., 2020] 将所有 NLP 任务统一为 Text-to-Text 格式——输入是文本，输出也是文本。翻译、问答、摘要、分类全部用同一架构处理。T5 的最重要贡献是系统的预训练目标对比实验

这段时期确立了三个核心思想，至今仍是 LLM 的基础 [Brown, Mann, Ryder, et al., 2020; Devlin et al., 2019; Raffel, Shazeer, Roberts, et al., 2020]：(1) 更大规模 = 更好性能，(2) 自监督预训练可替代人工标注，(3) Transformer 是通用序列建模架构。

第 1.4 节 规模化定律

Kaplan 等 [Kaplan, McCandlish, Henighan, et al., 2020] 系统研究了神经网络语言模型的缩放定律（Scaling Laws）：测试损失 L 与模型参数量 N 、训练数据量 D 、训练计算量 C 之间遵循幂律关系：

$$L(N) = \left(\frac{N_c}{N}\right)^{\alpha_N}, \quad L(D) = \left(\frac{D_c}{D}\right)^{\alpha_D}, \quad L(C) = \left(\frac{C_c}{C}\right)^{\alpha_C}$$

这个发现直接催生了 GPT-3 [Brown, Mann, Ryder, et al., 2020]——175B 参数，训练于 570GB 文本，展现出上下文学习（In-Context Learning）能力：无需微调，仅通过提示词中的少量示例即可完成新任务。

关键发展脉络：

- **Chinchilla 修正**：Hoffmann 等 [Hoffmann, Borgeaud, Mensch, et al., 2022] 发现 Kaplan 的定律低估了数据的重要性——**给定计算预算，模型参数和训练 token 数应等比增长**。70B 参数的 Chinchilla 用 1.4T tokens 训练，性能超过 280B 参数的 Gopher
- **涌现能力**：Wei 等 [Wei, Tay, Bommasani, et al., 2022] 系统记录了大模型的涌现能力（Emergent Abilities）——当模型规模超过某个临

界值时，之前不存在的思维链推理、指令遵循、多步算术等能力突然出现。这解释了为什么 BERT (340M) 没有 GPT-3 (175B) 那样的通用能力

- **PaLM**: Chowdhery 等 [Chowdhery, Narang, Devlin, et al., 2022] 将模型规模推到 540B 参数，展示了 **思维链提示 (Chain-of-Thought)** [Wei, X. Wang, Schuurmans, et al., 2022] 下的多步推理突破——在数学推理基准 GSM8K 上接近人类水平
- **LLaMA**: Touvron 等 [Touvron, Lavril, Izacard, et al., 2023] 证明仅用公开数据即可训练出有竞争力的 LLM，开启了开源 LLM 的浪潮

第 1.5 节 对齐：RLHF 与指令微调

规模化带来了能力，也带来了不可控性。GPT-3 可以生成流畅的文本，但不一定遵循用户意图——可能产生有害内容、编造事实（幻觉）、或忽视指令约束 [OpenAI, 2023; Kadavath, Conerly, Askell, et al., 2022]。

Ouyang 等 [Ouyang, Jeffrey Wu, Jiang, et al., 2022] 提出了基于人类反馈的强化学习 (RLHF):

1. **监督微调 (SFT)**: 用人类标注的高质量指令-回复对微调预训练模型
2. **奖励模型 (RM)**: 收集同一提示下的多个模型输出，由人类排序，训练一个奖励模型来预测人类偏好
3. **PPO 强化学习**: 用奖励模型作为奖赏信号，通过 PPO 算法进一步优化策略

1.3B 参数的 InstructGPT 就能在人类偏好评测中超过 175B 的 GPT-3，证明了对齐比规模更重要的原则 [Ouyang, Jeffrey Wu, Jiang, et al., 2022]。

GPT-4 [OpenAI, 2023; Achiam, Adler, Agarwal, et al., 2023] 进一步将 RLHF 扩展到多模态（文本+图像），在统一律师资格考试（Bar Exam）中排名前 10%，且通过红队测试和系统级安全措施大幅降低有害输出 [OpenAI, 2023]。

对齐的局限: RLHF 提升了指令遵循能力，但无法消除幻觉——LLM 仍可能自信地生成看似合理但完全错误的内容 [Kadavath, Conerly, Askell, et al., 2022]。这一缺陷是 Copilot 编译器反馈循环的**根本动机**: 人类使用 LLM 不是为了得到“可能正确的答案”，而是需要**经验证正确的代码**。

第 1.6 节 代码生成 LLM

LLM 在代码生成领域的突破始于 Codex [M. Chen, Tworek, Jun, et al., 2021]——一个基于 GPT-3 微调的代码专用模型，训练于 GitHub 公共仓库的 159GB Python 文件。Codex 在 HumanEval 基准上实现了 28.8% 的 pass@1 准确率 (GPT-3 仅 0%)，证明了领域特化训练的有效性。

后续发展：

- **StarCoder** [Li, Allal, et al., 2023]：在 The Stack (6.4TB 开源代码，358 种编程语言) 上训练的 15.5B 参数模型，采用 Multi-Query Attention 减少推理开销
- **GPT-4** [OpenAI, 2023]：通用模型的代码能力大幅提升，在 HumanEval 上达到 67% (零样本) 和 88% (结合自我修复)
- **Austin 等** [Austin, Odena, Nye, et al., 2021] 系统评估了 LLM 在程序合成中的表现，发现即使最强的模型在生成完整程序时仍有约 40% 的错误率

代码生成 LLM 的根本局限与本手册的核心论点直接相关 [M. Chen, Tworek, Jun, et al., 2021]：**LLM 生成的是统计概率最高的 token 序列，而非类型安全的程序。**它不理解类型系统 [Pierce, 2002]、无法保证跨文件一致性、不能验证 API 的真实存在性。这些正是编译器、类型系统和架构约束需要填补的空白。

第 1.7 节 Agent 范式

LLM 从“被动生成”到“主动执行”的转变，由 Agent 范式驱动：

- **ReAct** [Yao, Zhao, Yu, et al., 2023]：将推理 (Reasoning) 和行动 (Acting) 交织在一起——LLM 生成一个想法，根据想法调用工具，观察工具返回的结果，再生成下一个想法。ReAct 在知识密集型任务上将幻觉率从 20% 降到 12% [Yao, Zhao, Yu, et al., 2023]
- **Reflexion** [Shinn, Labash, and Gopinath, 2023]：在 ReAct 的基础上增加了口头强化学习——Agent 失败后，将执行轨迹和结果作为“反思”存入记忆，下次执行时利用反思避免重复错误。这直接启发了 Copilot 的编译器反馈循环

- **Self-Refine** [Z. Wang, Mao, Jason Wu, et al., 2023]: LLM 生成初稿后, 用自身的反馈进行迭代改进——不需要外部监督信号。在代码优化任务上, Self-Refine 将 pass@1 提升 10–20%
- **AutoGen** [Q. Wu, Bansal, Zhang, et al., 2023]: 多 Agent 协作框架——多个 LLM Agent 通过结构化对话协作完成任务, 支持角色分工 (编码员/审查员/测试员)、人工介入、代码执行沙箱

原则 1.7.1 (LLM 的理论边界). *LLM 的所有进步——从 Transformer [Vaswani, Shazeer, Parmar, et al., 2017] 到 RLHF [Ouyang, Jeffrey Wu, Jiang, et al., 2022] 到 Agent [Yao, Zhao, Yu, et al., 2023]——都未触及一个根本问题: LLM 的输出是概率性的, 不是确定性的。*

Scaling Laws [Kaplan, McCandlish, Henighan, et al., 2020; Hoffmann, Borgeaud, Mensch, et al., 2022] 说规模越大、性能越好——但对数收益。涌现能力 [Wei, Tay, Bommasani, et al., 2022] 说更大的模型有新能力——但不可预测何时出现。RLHF 说可以对齐——但无法消除幻觉 [Kadavath, Conerly, Askell, et al., 2022]。

Copilot 的存在理由, 就是为 LLM 的模糊输出提供确定性的外部约束。编译器 [Aho et al., 2006] 不会产生幻觉。类型系统 [Pierce, 2002] 不会产生幻觉。权限白名单不会产生幻觉。这些都是 LLM 所完全欠缺的——本手册要构建的正是这座桥梁。[S. Chen, 2024]

第 1.8 节 孔洞驱动开发(Hole-driven Development)

LLM 在面对复杂 F# 逻辑时, 往往因为一次性输出过多而导致类型推断混乱。模型试图在一次生成中完成整个函数的实现, 结果是概率空间的大跨步跃进——每一步都可能累积类型错误。

解决方案: 引入孔洞驱动开发——允许 LLM 在概率不确定时输出占位符:

```
1 // LLM 对某些类型推导不确定时, 用孔洞代替
2 let processUser user =
3     let enriched = ??todo_hole // ← 孔洞: LLM 承认此处不确定
4     enriched
```

L3 FCS 拦截器捕获 `todo_hole` 位置，提取该上下文的精确类型需求（从 FCS 的类型检查结果中获得该位置的唯一合法类型），反向注入给 LLM 作为下一轮的上下文：

1. LLM 生成含孔洞的代码 → L3 编译检查 → FCS 返回该孔洞位置的期望类型
2. Copilot 将期望类型格式化为精确的补全指令 → 注入 LLM 提示词
3. LLM 只填充孔洞（而非重新生成整个函数）→ 第 2 轮编译通过率大幅提升

原则 1.8.1 (非对称收敛)。孔洞驱动的本质是将单次大跨步生成解构为多次小步收敛。LLM 不需要一次性猜对所有类型——只需要在编译器反馈的引导下，逐步填补不确定的区域。每一步的搜索空间都远小于上一步。

这是非对称收敛 (Asymmetric Convergence)：搜索空间随进度指数级缩小，而非线性反思中的恒定搜索空间。

第 1.9 节 语义空间缩减率的形式化

在 § 1.6 讨论 JCS 约束时，可以形式化地量化架构约束对生成空间的影响：

定义 1.9.1 (语义空间缩减率)。设 LLM 在无约束条件下的合法代码生成空间为 Ω_{raw} ，在 JCS 约束 (Design-*.json 锁定的接口 Functor 映射) 下的合法生成空间为 Ω_{JCS} 。则：

$$\text{缩减率 } \rho = \frac{|\Omega_{\text{JCS}}|}{|\Omega_{\text{raw}}|} \ll 1$$

直观理解：

- Ω_{raw} ：LLM 可以生成任意 F# 代码——任意函数签名、任意类型定义、任意模块引用。搜索空间 = 无穷大（组合爆炸）
- Ω_{JCS} ：JCS 锁定 RPC 接口的 Functor 映射后——API 签名的输入/输出类型已由 Design-*.json 确定，函数的骨架（管道结构、错误处理模式）已由 ROR 约定固定。LLM 只在业务逻辑上有自由度——搜索空间缩小了数个数量级

这种确定性降维打击的理论依据：

- 原生 F# 的合法代码空间 $\approx$ 所有可能的 token 序列

- JCS 约束后的合法代码空间 $\approx$ 所有可能的业务逻辑 token 序列（骨架已确定）
- 后者远小于前者——这就是为什么在 JCS 体系下 LLM 的正确率显著提升

原则 1.9.1 (约束即降维). 每增加一层约束 (类型 $\rightarrow$ 架构 $\rightarrow$ 命名约定 $\rightarrow$ ROR 模式), Ω 就缩小一个数量级。LLM 的正确率与 Ω 的大小成反比。

这不是“限制 AI 的创造力”——这是将 AI 从不可能完成的任务（在无穷空间中搜索）解放到可能完成的任务（在有限空间中搜索）。

第 2 章

复盘：CodeBuddy 原生实践中的 LLM Agent 失控

第 2.1 节 为什么要复盘？

在讨论理论方案之前，必须先审视**现实**——一个真实的 LLM Agent（CodeBuddy）在为期一周的生产级开发中，暴露出了哪些问题，造成了多大的损失，以及**仅靠提示词工程能否解决**这些问题。

本节基于 <c:/Dev/codebuddy/log/> 目录下 2026-06-23 至 2026-06-30 的 64 条审计日志，提炼出五类典型事故。

第 2.2 节 五大典型事故

第 2.2.1 节 走错项目（2026-06-29 21:15）

场景：用户报告 “demo 下没看到前端渲染技术菜单”。

- **Agent 行为：**搜索 Aiarwa 项目目录 → 未找到目标文件 → **跳转到 AIO 项目**（桌面应用 AvaloniaApp）→ 排查方向完全错误

- **根因**: Aiarwa 前端任务在 02:04 已由之前的会话完成, Agent 未先读取当日 memory
- **损失**: 3 轮对话浪费, 5 次无效 tool call
- **本质**: LLM 没有“我在哪个项目”的明确约束——它拥有搜索所有目录的自由, 却无法区分搜索结果的相关性 [Yao, Zhao, Yu, et al., 2023]

第 2.2.2 节 产线宕机: develop 白名单误匹配 (2026-06-29 19:35)

场景: 部署 Aiarwa 到生产服务器 192.168.5.5, 结果 kayhuaoil.com 无法访问。

- **Agent 行为**: 部署后报告“服务启动成功”——只检查了 `systemctl is-active`
- **实际状态**: `Program.fs` 中 develop 白名单包含了生产服务器 hostname → 服务绑定了 AI 调试端口 5290/5291, 而非人类端口 9020/9021 → Cloudflare Tunnel 502
- **损失**: 产线完全不可用 16 小时; 80 分钟紧急排查
- **本质**: Agent 的“成功”判断过于粗糙——进程存活 $\neq$ 服务可用。缺少端口级别和 HTTP 级别的自动验证

第 2.2.3 节 SSH 死锁: 基于虚假信息诊断 (2026-06-28 22:00)

场景: WYI 部署到 Hetzner VPS, 需要配置 SSH 免密登录。

- **Agent 行为**: 子 agent (code-explorer) 报告 `id_rsa` 文件存在且已加密 → Agent 花 ~30 分钟诊断 passphrase 问题
- **实际状态**: 文件根本不存在——子 agent 返回了错误信息 [Kadavath, Conerly, Askell, et al., 2022]
- **损失**: ~32,000 tokens, ~40% 浪费在错误方向上
- **本质**: LLM Agent 无法区分“工具返回的信息”和“客观事实”——缺少对子 agent 结果的强制二次验证

第 2.2.4 节 PID 误杀（2026-06-29 多次）

场景：调试结束后需要清理进程。

- **Agent 行为**：直接执行 `taskkill /F /T /PID <PID>`——没有先确认该 PID 是否是 CodeBuddy 自身的进程
- **实际状态**：两次误杀了 CodeBuddy CN 隧道进程，导致 IDE 崩溃
- **本质**：LLM Agent 没有“什么不能杀”的概念——`taskkill` 是盲操作，缺少 PID 身份预检

第 2.2.5 节 提示词优化的天花板（2026-06-29 全天）

场景：2026-06-29 单日生成 36 条审计日志，包含大量规则补丁和提示词优化。

- **现象**：每踩一个坑，就在 `always_applied_user_rules` 中追加一条规则——“每次必须先读 memory”“`taskkill` 前必须 `tasklist`”“子 agent 返回值必须二次验证”……
- **结果**：规则已从最初的 5 条膨胀到 40+ 条（~3,000 words），每次会话的上下文开销 ~4,000 tokens
- **本质**：**提示词工程的边际收益递减**——每增加一条规则，LLM 的正确执行概率只提升 2-5%，但规则越多越容易被忽略（“attention dilution”）[Liu, Lin, Hewitt, et al., 2023]

第 2.3 节 根因归纳

事故类型	频次	根因	缺失的能力
走错项目	2 次/周	无项目上下文锁定	工作区隔离
端口误配	2 次/周	无端口级验证	部署验证自动化
虚假信息	3 次/周	子工具结果不可信	结果二次验证
PID 误杀	2 次/周	无进程身份判断	操作前预检
规则膨胀	持续	提示词边际收益递减	外部约束机制

原则 2.3.1 (复盘结论). 原生的 LLM Agent 在复杂项目中会犯系统性错误。这些问题无法通过增加提示词规则来解决——规则的边际收益趋近于零，而项目的复杂度没有上限 [Liu, Lin, Hewitt, et al., 2023]。

必须引入外部约束机制——类型系统、编译器反馈、文件权限、进程白名单——将 LLM Agent 的自由度限制在安全边界内。

第 2.4 节 L4 拦截器深度加固：幂等性守卫与行为影子化

复盘中的 PID 误杀和产线宕机事故，暴露了 L4 执行层的一个根本缺陷：仅靠 PID 过滤无法完全阻止破坏性操作。rm -rf、错误的数据库清洗、配置覆盖等操作在 MCP 协议层可能完全合法——参数格式正确、ACL 通过、白名单放行——但其业务后果是灾难性的。

第 2.4.1 节 命令白名单与幂等性校验

L4 执行层必须追加两层校验：

1. **命令白名单**：只有经过审计确认安全的命令才允许执行。不在白名单中的命令，即使通过了 ACL 也拒绝执行，转而提示用户手工确认
2. **幂等性守卫 (Idempotency Guard)**：对于文件写入和数据库操作，必须在操作前检查是否已经执行过等效操作。幂等操作（如将已运行的端口再启动一次）是安全的；非幂等操作（如删除未备份的数据）必须提升到最高风险等级

第 2.4.2 节 行为影子化 (Shadowing)

进一步的安全加固：任何 WriteFile 或 ExecuteCommand 在未通过完整安全校验前，不直接作用于目标路径。

定义 2.4.1 (行为影子化)：所有潜在的破坏性操作首先写入系统临时隔离区 (/tmp/codebuddy_sandbox/)，源文件不动。仅当以下条件全部满足时，才通过原子性的 Move/Symlink 覆盖目标路径：

1. L3 编译检查通过（写入的是合法代码）
2. L5 监控无异常信号（Token 用量正常、无频繁重试）
3. 目标路径不在受保护列表（TypeSys 生成区、配置文件）

4. 操作的类型在下一校验中确认幂等或可回滚

```
1 (* L4 影子写入拦截器 *)
2 let shadowRoot = "/tmp/codebuddy_sandbox/"
3
4 let shadowWrite (targetPath: string) (content: byte[]) =
5     let shadowPath = shadowRoot + (hashPath targetPath)
6     // 1. 写入影子
7     File.WriteAllBytes(shadowPath, content)
8     // 2. 编译检查 (L3 回调)
9     match compileCheck shadowPath with
10    | Fail e ->
11        File.Delete(shadowPath) // 清理影子
12        Deny (sprintf "编译失败: %s" e)
13    | Suc _ ->
14        // 3. 原子性移动
15        File.Move(shadowPath, targetPath, overwrite = true)
16        Allow "影子写入成功"
```

原则 2.4.1 (零信任写入). 在 L4 执行层, 没有任何写入操作是默认可信的。所有写入必须经过影子 → 编译验证 → 原子移动的三阶段流程。

这保证了即使 L3 编译检查存在假阴性 (某些编译错误未被捕获), 影子化的文件也不会污染项目源码。最坏情况: 影子文件被丢弃, 源文件完好无损。

第 3 章

架构约束

第 3.1 节 为什么要讨论架构？

LLM 生成代码的可靠性，不仅仅取决于模型的推理能力，更取决于**生成目标所处的架构环境**。一个混乱的、缺乏约束的架构会让 LLM 有无限的可能性去“猜”——而猜对的概率极低 [M. Chen, Tworek, Jun, et al., 2021]。

相反，一个严格定义的架构会将 LLM 的可能输出空间大幅缩减。本章从实际项目（JCS 体系）出发，阐述架构层面的约束如何辅助 AI 编程。

第 3.2 节 全栈架构概览

项目采用 F# .NET + Kestrel 后端，Vue 3 + TypeScript + Vite 前端，PostgreSQL 数据库，Cloudflare Tunnel 内网穿透。

- **F#**：函数式优先，类型安全，Railway Oriented Programming 天然适配服务端错误处理；|> 管道化极高代码密度 [Syme, Granicz, and Cisternino, 2007]
- **Kestrel**：.NET 原生 Web 服务器，无需 Nginx 反向代理
- **PostgreSQL**：JSONB 支持、全文搜索、窗口函数
- **Vue 3 + Bun + Vite**：极速开发体验，Composition API

- **TypeSys**: 自研跨语言代码生成器，消除前后端类型不同步
- **不使用 Pinia/Vuex**: `globalThis.runtime + reactive()` 极简状态管理

第 3.3 节 核心架构理念 —— RPC as Functor

整个体系的核心理念是**类型安全的跨语言 RPC**。其理论基础来自范畴论 [S. Chen, 2024; Lane, 1971]:

定义 3.3.1 (RPC 函子). 设 L_1 为后端语言 (F#) 构成的范畴, L_2 为前端语言 (TypeScript) 构成的范畴。RPC 函子 $F : L_1 \rightarrow L_2$ 将:

- L_1 中的类型映射为 L_2 中的类型
- L_1 中的远程函数映射为 L_2 中的虚拟本地函数

且满足交换图: $F(f(x)) = f'(F(x))$ 。

这一理论的直接工程落地是 JCS TypeSys 代码生成器——从单一元数据源 (`Design*.json`) 自动生成 F# 和 TypeScript 两端的类型定义和序列化代码。

第 3.4 节 架构对 AI 编程的约束

1. **统一四层架构**: 所有项目遵循 `Server → BizLogics → Shared → Common` 的固定分层。AI 生成的代码必须落在正确的层级中，不能跨层访问。
2. **API 字典分发**: API 通过 `apiBuilder` 字典分发 (11 个 handler), AI 新增 API 必须遵循 `api_h` 命名约定和字典注册模式。
3. **Session 在 JSON body**: 不在 Cookie/Header 中传递, AI 生成的请求代码必须将 session 放在 JSON body 中。
4. **Railway Oriented Programming**: 后端返回值必须使用 `CtxWrapper<'ctx, 'ex> = Suc of 'ctx | Fail of 'ex * 'ctx` 模式, 禁止用异常控制流。
5. **全局状态用 globalThis**: 前端状态管理不使用 Pinia/Vuex, 统一通过 `globalThis.runtime + reactive()` 实现。

原则 3.4.1 (架构约束原则). 架构不是枷锁, 而是**精确的导航系统**。当 LLM 知道代码必须落在第几层、通过什么通道通信、使用什么错误处理模式时, 其

生成代码的正确率会显著提升。混沌的架构给 LLM 无限的自由度——等于无限的犯错机会 [Pierce, 2002]。

第 3.5 节 LLM 代码生成的现状与局限

在缺乏架构约束的环境下，LLM 代码生成面临以下问题：

1. **语法错误**：生成的代码可能缺少分号、括号不匹配
2. **类型错误**：在静态类型语言中，LLM 可能生成不符合类型约束的代码
3. **逻辑错误**：代码能够编译，但逻辑不正确
4. **幻觉问题**：LLM 可能生成不存在的 API 或库函数 [M. Chen, Tworek, Jun, et al., 2021; Brown, Mann, Ryder, et al., 2020]

传统约束方法（系统提示词、少样本学习、后处理校验）共有的问题：**约束不够严格**。这正是需要引入编译器和类型系统约束的原因。

第 4 章

编译器（含类型系统）约束

第 4.1 节 编译器不是第二大脑

许多 AI 辅助编程的讨论将编译器比喻为“LLM 的第二大脑”——这个比喻是**错误的**。

编译器不是 AI 的辅助工具，而是**人类智慧的精华**。它是人类将自然语言中的逻辑用形式化语言（Formal Language）表达的产物，通过严格的语法规则和类型系统，将模糊的人类意图转化为精确的机器指令 [Aho et al., 2006]。

编译器 = 自然语言的形式化约束层

LLM 的**根本缺陷**，恰恰在于缺乏这种形式化的能力。LLM 生成的是统计概率最高的 token 序列，而非逻辑完备的规约（Specification）[Vaswani, Shazeer, Parmar, et al., 2017]。它不理解：

- **类型一致性**：一个 `int64` 不能赋值给 `string`
- **作用域规则**：局部变量不能跨函数访问
- **副作用控制**：纯函数不能修改外部状态
- **模式匹配完备性**：F# 的 `match` 表达式必须覆盖所有分支

编译器知道所有这些——而且**永远不会忘记**。这不是 LLM 的“第二个大


脑”，这是 LLM 所完全欠缺的那部分。

第 4.2 节 类型系统是自然语言的离散化

定义 4.2.1 (类型即约束). 类型系统本质上将连续的自然语言语义空间，**离散化**为有限个精确类别 (int32、string、bool、T__User)。每个类型定义了一个合法值的集合，编译器确保程序中的每个值都属于其声明的集合 [Pierce, 2002]。

LLM 在连续嵌入空间中操作——它对每个 token 的理解是分布式的、模糊的。编译器在离散空间中操作——它对每个值的理解是确定性的、精确的。这两个空间之间的鸿沟，正是 AI 编程出错的主要来源 [Vaswani, Shazeer, Parmar, et al., 2017]。

原则 4.2.1 (类型系统 = 精度放大器). 类型系统将 LLM 的模糊概率输出，通过编译器检查转化为精确的确定性输出。这不是“限制 AI 的创造力”——这是**弥补 AI 的精度缺陷**。就像示波器将模拟信号转化为数字信号——编译器将 LLM 的模糊输出转化为可验证的数字信号 [P. Cousot and R. Cousot, 1977]。



错误反馈 LLM 重生成 [Shinn, Labash, 2023]

图 4.1: 编译器作为精度放大器：将 LLM 的模糊输出转化为确定性结果

第 4.3 节 类型约束注入

第 4.3.1 节 类型信息的提取

从项目的类型定义文件中提取类型信息。在 JCS 体系中，类型定义来自 TypeSys 自动生成的 `OrmTypes.fs` 或 `OrmTypes.d.ts`：

例 4.3.1 (F# 类型定义)。

```
1 (* OrmTypes.fs — TypeSys 自动生成 *)
2 type T__User = {
3     Id: int64
4     Name: string
5     Email: string
6     CreatedAt: DateTime
7 }
8
9 type T__Project = {
10     Id: int64
11     Name: string
12     OwnerId: int64
13     CreatedAt: DateTime
14 }
```

需要提取：

- 类型名称 (T__User, T__Project)
- 字段名称与类型 (Id: int64, Name: string)
- 命名约定 (T__U 双下划线格式)

第 4.3.2 节 注入到提示词

系统提示词模板：

```
1 你是一个专业的
2  F# 开发者。请严格遵守以下类型约束：类型约束（必须遵守）：
3
4
5  - T__User: { Id: int64, Name: string, Email: string, CreatedAt: DateTime }
6  - T__Project: { Id: int64, Name: string, OwnerId: int64, CreatedAt: DateTime }代码风格
7
8
9  1. 使用 |> 管道化语法
10 2. 使用 Railway Oriented Programming (CtxWrapper)
```

```
11 3. T__U 双下划线命名 (转换函数)
12 4. empty__Type 工厂函数注意:
13
14
15 1. 生成的代码必须能够通过 F# 编译器检查
16 2. 不要生成不存在的类型或函数
17 3. 使用类型推断, 减少显式类型注解
```

第 4.3.3 节 类型推断的作用

在 F# 中, 类型推断可以自动推导变量类型, 减少 LLM 的类型错误 [Syme, Granicz, and Cisternino, 2007]。

例 4.3.2 (F# 类型推断).

```
1 (* 编译器自动推断类型 *)
2 let getUserEmail user =
3     user.Email (* 编译器知道 user: T__User, Email: string *)
4
5 let formatUser (user: T__User) =
6     let name = user.Name.ToUpper() (* Name: string *)
7     let year = user.CreatedAt.Year (* CreatedAt: DateTime *)
8     (name, year)
```

第 4.4 节 编译器反馈循环

第 4.4.1 节 基本流程

1. **生成代码**: LLM 根据提示词 (含类型约束) 生成代码
2. **编译检查**: 将代码写入临时文件, 调用 F# 编译器检查
3. **提取错误**: 如果编译失败, 提取错误信息 (错误位置、错误原因、FS 错误代码)
4. **反馈重生成**: 将错误信息作为上下文, 反馈给 LLM, 重新生成 [Shinn, Labash, and Gopinath, 2023]
5. **循环直到成功**: 重复步骤 1-4, 直到编译通过或达到最大重试次数

第 4.4.2 节 LLM 欠缺的形式化能力

原则 4.4.1 (人类的形式化 vs LLM 的模糊性). 人类通过编译器将模糊思想转化为精确代码——这是几千年来形式化思维的结晶 [Aho et al., 2006]。LLM 没有这种能力——它只能在训练数据的统计分布中寻找最可能的 token 序列 [Vaswani, Shazeer, Parmar, et al., 2017; Brown, Mann, Ryder, et al., 2020]。编译器反馈循环的本质，就是用人类的形式化工具来弥补 LLM 的形式化缺陷。

第 4.4.3 节 命名约定作为类型约束的延伸

F# 代码库中存在严格的命名约定，这些约定本身是一种**隐式类型约束**：

模式	格式	示例
类型转换函数	T__U（双下划线）	json__str, str__bin
工厂函数	empty__Type	empty__Stats()
序列化对	pType__f / f__pType	pBOOK__bin / bin__pBOOK
数据库操作	db__pType	db__pBOOK, BOOK_create

第 4.5 节 效果评估

- **编译成功率**：> 90%（无反馈循环时约 60%）[M. Chen, Tworek, Jun, et al., 2021]
- **平均重试次数**：1.5 次（无反馈循环时 3–5 次）
- **Token 使用**：节约约 30%（减少无效生成）

第 4.6 节 FCS 深度集成——从编译器到代码修复器

选定 F# 作为 Copilot 的核心宿主后，不能只把 `FSharp.Compiler.Service` (FCS) 当作一个“快速编译器”来用。FCS 的能力远超编译检查——它是完整的 F# 前端，能提供 AST 解析、符号解析、语义分类等深层能力。应将其升级为**代码修复器 (Code Fixer)**。

第 4.6.1 节 实时 AST 重写

当 LLM 输出的代码产生编译错误时，L3 拦截器不应该只把错误文本丢回给 LLM——而是利用 FCS 的 AST 信息和符号表，在将错误返回 LLM 之前先进行语义增强：

- 1. **AST 解析**：FCS 的 ParseFile 返回完整的未类型化 AST（Untyped AST）——即使代码有类型错误，语法树仍然可以构建
- 2. **错误定位**：FCS 诊断信息精确到文件/行列/错误码/关联符号
- 3. **上下文提取**：从错误位置的 AST 节点出发，提取：
 - 该函数/模块的完整签名
 - 该位置使用到的所有外部符号（来自 FSharpSymbolUse）
 - 类型推导链——编译器在出错前已经推导出的部分类型信息
- 4. **强推入上下文**：将以上信息格式化为结构化 Markdown 表格，替代原始错误文本作为 LLM 下一轮的反馈输入

第 4.6.2 节 GetSemanticClassification 强推入——以 FS0041 为例

当模型输出的代码产生 **FS0041（方法重载解析失败）** 时，传统的做法是把 "error FS0041: 无法确定重载的唯一方法" 丢回给 LLM——LLM 只能凭记忆猜测哪些重载可用，重试 4-5 次是常态。

增强型反思路径：

- 1. FCS 编译失败 → 捕获 FS0041 错误码
- 2. 调用 FSharpChecker.GetSemanticClassification 在该错误位置提取所有合法的重载签名列表
- 3. 将这些签名格式化为表格，**强制推入** LLM 的下一轮提示词：

```
1 FS0041 修复建议（以下为该位置可用的全部重载签名）：
2
3 | 签名 | 参数 | 返回类型 |
4 |-----|-----|
5 | db__pBOOK(query: string) | string | BOOK option |
6 | db__pBOOK(query: string, ...cols: string[]) | string * string[] | BOOK list |
7 | db__pBOOK(query: DbQuery) | DbQuery | BOOK list | 请选择与目标业务逻辑最匹配的重载
```

原则 4.6.1 (FCS 不是编译器的替代品，是编译器的增强器). 传统流程: LLM

生成代码 → 编译器报错 → 错误文本返回 LLM → LLM 猜测修复。重试次数 = 4-5 次，因为 “错误文本” 对 LLM 的信息量太低。

增强流程：LLM 生成代码 → 编译器报错 → **FCS 提取该上下文的合法签名/符号/类型** → 以结构化表格注入 LLM → LLM 在精确信息指导下修复。重试次数 → 1-2 次。

从编译器反馈到代码修复器的升级，就是让 FCS 成为 LLM 与 F# 编译器之间的语义翻译层。

第 5 章

JCS 与自动生成代码的保护约束

第 5.1 节 JCS 的理论基础

JCS (J-Category Systems) 体系的核心理念是类型安全的跨语言 RPC, 其理论基础见 [S. Chen, 2024]。

$$\begin{array}{ccc} L_1 & \xRightarrow{F} & L_2 \\ \downarrow f & & \downarrow F(f) \\ L_1 & \xRightarrow{F} & L_2 \end{array}$$

交换图: $F(f(x)) = f'(F(x))$ ——RPC 函子保证跨语言等价 [Lane, 1971]

第 5.1.1 节 JCS 是严格的确定性知识描述映射

JCS 体系的核心特征:

1. **单一元数据源:** `Design-*.json` 是所有类型定义的唯一真相源 (Single Source of Truth)

- 2. **确定性生成**: 从元数据到 F#/TypeScript/SQL 代码的映射是**完全确定**的——同一个 Design 文件永远产生相同的输出
- 3. **全量重新生成**: 每次生成都是全量的, 不存在增量更新或手动合并
- 4. **跨语言一致**: F# 端、TypeScript 端、SQL 端的类型定义**自动保持同步**

这就是 LLM 所**完全欠缺**的东西: **确定性的、从元知识到实际代码的精确映射**。LLM 能“理解”类型——但它永远无法保证每次生成一致的输出。JCS 能——因为它不是 AI, 它是严格的代码生成器。

第 5.2 节 TypeSys 代码生成流水线

JCS 体系的核心工具 TypeSys 是一个**离线代码生成器**, 从单一元数据源生成 F#、TypeScript 和 SQL 代码, 支持 12 个项目配置:

```
1 Design-*.json 实体定义 ()
2   -> TypeSys/Program.fs 读取设计文件 ()
3   -> CodeRobotIIFs.fs 生成 ( F# ORM 代码)
4   -> CodeRobotIITs.fs 生成 ( TypeScript ORM 代码)
5   -> OrmTypes.fs (F# record 定义)
6   -> OrmMor.fs (F# CRUD + 序列化)
7   -> OrmMor.ts (TypeScript CRUD + 序列化)
8   -> OrmTypes.d.ts (TypeScript 类型声明)
9   -> sqlPostgreSQL.sql / sqlSQLServer.sql 数据库迁移 ()
```

第 5.3 节 生成代码禁止手动修改

AI 绝对不能直接修改 TypeSys 生成的文件。每次生成都从 [Design-*.json](#) 全量重新生成, 手动修改会被覆盖。

禁止直接修改的文件清单:

文件	所属端
OrmTypes.fs, OrmMor.fs, CustomMor.fs, Types.fs	F# 端
OrmMor.ts, CustomMor.ts, OrmTypes.d.ts, Types.d.ts	TypeScript 端
sqlPostgreSQL.sql, sqlSQLServer.sql, OrmTypes.sql	SQL 端

第 5.3.1 节 正确的修改流程

方案 A（优先，推荐）：离线 TypeSys 直接运行

```
1 修改
2 Design-*.json
3 -> dotnet run TypeSys/Program.fs
4 -> 代码重新生成
5 -> 继续修改程序其他部分
```

优点：快，无需编译后端；无运行时错误风险。

方案 B（兜底）：后端启动自生成

```
1 修改
2 Design-*.json
3 -> 编译运行后端
4 -> 后端启动时自动根据元数据修改源码
5 -> 关闭后端
6 -> 继续修改程序其他部分
```

缺点：耗时长（编译 + 启动 + 关闭），可能遇到运行时错误。

第 5.4 节 LLM 与 JCS 的对比：确定性 vs 模糊性

维度	JCS / TypeSys	LLM
输出一致性	确定：同一输入 → 同一输出	不确定：同一输入 → 不同输出 [Brown, et al., 2020]
类型安全	编译期保证 [Pierce, 2002]	仅概率保证
跨语言同步	自动：改元数据 → 两端更新	无法保证
知识表示	结构化：JSON schema	分布式：嵌入 [Shazeer, Parmar, et al., 2017]
可验证性	可证明：编译 = 数学证明	无法证明

原则 5.4.1 (确定性的力量). *JCS 证明了：对于可形式化的知识（数据库 Schema、类型定义、序列化规则），确定性代码生成是可行的。LLM 在这些场景下不是增强，而是引入不确定性—— 让一个概率系统替代一个确定性系统，是方向性错误。*

正确的做法是：LLM 负责不可形式化的部分（用户意图、业务逻辑），JCS/编译器负责可形式化的部分（类型、序列化、Schema）。

第 5.5 节 JCS 对 Copilot 的启示

1. **单一真相源**：TypeSys 的 `Design-*.json` 是数据结构的唯一定义——Copilot 也应从单一元数据源提取类型信息，避免不一致
2. **自动生成 + 手动禁止**：生成器保证一致性，禁止手动修改保证持久性——Copilot 的拦截器也应区分“可修改”和“只读”区域
3. **离线工具优先**：TypeSys 作为离线工具运行，快且无运行时风险——Copilot 的编译检查也应在隔离的临时目录进行
4. **确定性优先**：可形式化的部分用确定性的代码生成器，不可形式化的部分用 LLM——不要因为 LLM 流行就放弃确定性方案

第 5.6 节 只读文件系统钩子与增量式单向同步

手册规定禁止 LLM 修改 `OrmTypes.fs` 等 TypeSys 生成文件。但“规定”需要代码级强制执行——仅靠提示词无法保证 LLM 不会误修改受保护文件。

第 5.6.1 节 只读 VFS 钩子 (Read-Only VFS Hook)

在 L4 执行层实现文件系统钩子，对所有写操作进行路径拦截：

```

1 (* 显式定义受保护的 JCS 核心生成路径 *)
2 let protectedPaths = [ "OrmTypes.fs"; "RpcHandlers.fs"; "DbSchema.fs" ]
3
4 let verifyFileAccessInterceptor (requestedPath: string) (action: FileAction) =
5     let fileName = System.IO.Path.GetFileName(requestedPath)
6     if List.contains fileName protectedPaths && action = Write then
7         // 拒绝写入，强制降级并返回标准化错误提示词
8         Deny (sprintf
9             "拒绝修改由 JCS 生成的核心类型文件 %s" +
10             "请在 Design-*.json 中修改规约，并运行 TypeSys 重新生成。"
11             fileName)
12     else
13         Allow
  
```

关键设计：

- **仅匹配文件名**：Path.GetFileName 防止路径绕过 (`./OrmTypes.fs`、`../OrmTypes.fs` 等)，不依赖路径字符串比较

- **标准化拒绝消息**：每次拦截返回完全相同的提示词片段——LLM 会迅速学会 “不要修改生成文件”
- **操作类型感知**：Read 操作不拦截（可以读取生成文件的类型信息），仅 Write/Delete 被拦截

第 5.6.2 节 增量式单向同步（Incremental One-Way Sync）

当前 TypeSys 生成是全量的——每次运行从 `Design-*.json` 重新生成所有文件。在 Copilot 环境中，全量重新生成的开销太大（触发多文件写入 → 触发 VFS 钩子检查 → 触发 IDE 热重载）。

增量式单向同步的改进方案：

1. **仅修改 `Design-*.json`**——这是唯一合法的手动编辑入口
2. **TypeSys 增量生成**：仅重新生成受影响的文件子集（而非全部 12 个项目输出），通过依赖图判断影响域
3. **单向只读映射**：生成的 F#/TS/SQL 文件在 Copilot 的 VFS 层中标记为只读挂载点——LLM 可见（可引用类型），但不可写
4. Copilot 的 L1 层从生成文件中读取类型约束（用 FCS 解析），而非直接读取 `Design-*.json` ——这样 TypeSys 的生成逻辑和 Copilot 的类型提取逻辑保持解耦

原则 5.6.1 (生成代码的不可写性). 生成代码的 “不可修改性” 现在不是一条提示词规则，而是一个文件系统级别的强约束。

LLM 尝试写入 `OrmTypes.fs` → VFS 钩子拦截 → 返回标准化拒绝消息 → LLM 接收明确信号 → 转而修改正确的入口 (`Design-*.json`)。

从言语禁止到物理隔绝——这是 Copilot 安全体系的核心升级路径。

第 6 章

Copilot 的设计规范

第 6.1 节 设计目标

Copilot 系统的设计目标是：在保留 LLM 代码生成能力的前提下，通过多层约束机制，将编译成功率从 $\sim 60\%$ 提升到 $> 90\%$ ，同时控制 Token 消耗和重试次数。

第 6.2 节 提示词优化的天花板——来自 Dev Skill 的实践

在 CodeBuddy 的 Dev Skill 整理实践中，从 2026-06-23 到 2026-06-30 积累了大量**提示词优化经验**，也触碰到了提示词工程的上限：

- **规则膨胀**：从最初的 5 条铁律膨胀到 40+ 条 ($\sim 3,000$ words)，每条新规则都在解决之前踩过的坑
- **边际收益递减**：第 1 条规则提升 30% 正确率，第 10 条规则提升 5%，第 30 条规则几乎无影响（LLM 注意力被稀释）[Liu, Lin, Hewitt, et al., 2023]
- **记忆系统三级**：L1（路由表 173 行）+ L2（14 个项目/工具文件）+ L3（深度架构文件 10 个）+ Memory（70+ 条）—— **这套系统本身就是对**

LLM 上下文限制的被迫适应

- **脚本化强制流程**：ai-debug-init.ps1 的诞生说明——连 “读取正确的端口配置” 这样的任务，都无法信任 LLM 的提示词来保证，必须外部脚本强制执行

原则 6.2.1 (提示词天花板). 提示词工程的收益曲线是**对数曲线**：前几条规则收益极高 (~30% 正确率提升), 但很快进入平台期 (~2-5% 每条), 最终趋近于零 (attention dilution) [Liu, Lin, Hewitt, et al., 2023; Wei, X. Wang, Schuurmans, et al., 2022].

这意味着：无论投入多少精力优化提示词，LLM 的错误率都有一个无法逾越的下界。要突破这个下界，必须引入提示词之外的约束——编译器检查、类型约束注入、文件权限控制、进程白名单。




图 6.1: 五层拦截器架构: L1 预处理 → L2 路由 → L3 后处理（含编译器反馈循环）→ L4 执行 → L5 监控

第 6.3 节 五层拦截器架构

1. **L1: 提示词预处理器** —— 注入类型约束、检测危险操作。从 TypeSys 生成的类型文件中提取类型信息，注入到系统提示词中。检测可能破坏项目结构的操作（如删除生成文件、修改项目配置）。
2. **L2: 模型路由层** —— 根据任务类型选择合适的模型。代码生成用本地

Ollama (qwen2.5-coder:14b), 复杂推理用 DeepSeek-R1, 通用任务用 qwen2.5:14b。

3. **L3: 后处理拦截器 (核心)** —— 编译检查、类型约束验证、权限检查。将 LLM 生成的代码写入临时目录 → 编译器检查 → 提取错误 → 反馈 LLM 重生成 [Shinn, Labash, and Gopinath, 2023; Z. Wang, Mao, Jason Wu, et al., 2023]。 **不等同于中止——而是修正后重试。**
4. **L4: 执行层 (严格权限)** —— 文件写入只允许特定目录、数据库只读、命令白名单。TypeSys 生成文件区域**绝对禁止写入**。文件写入限制在临时目录和用户指定的合法区域。
5. **L5: 监控与反馈层** —— 全链路日志、实时统计、自动调整。记录每次 LLM 调用的 Token 消耗、编译结果、重试次数。当编译成功率低于阈值时, 自动增强约束或切换模型 [Q. Wu, Bansal, Zhang, et al., 2023]。

第 6.4 节 为什么需要比 MCP 更强的约束?

MCP (Model Context Protocol) [Anthropic, 2024] 提供了工具层的标准协议, 但它只能约束**工具调用** (参数校验、权限控制), 无法约束:

- LLM 的**思考过程** (LLM 可能生成错误的推理链)
- LLM 的**输出格式** (代码质量、类型正确性)
- **资源使用** (Token 消耗、重试次数)
- **环境状态** (LLM 不清楚服务器端口、数据库连接、文件权限)

因此需要在 MCP 之上构建**多层次拦截器** [Q. Wu, Bansal, Zhang, et al., 2023]。

原则 6.4.1 (拦截器 ≠ 中止按钮). *Agent SDK* 的拦截能力不等同于中止会话按钮。中止 = 强制停止, 不可恢复。拦截器 = 可以**修改、重试、降级**。编译失败 → 提取错误 → 反馈给 LLM 重生成, 这才是比中止更有价值的机制 [Z. Wang, Mao, Jason Wu, et al., 2023]。

	中止会话按钮	拦截器
动作	强制停止	修改/重试/降级
可恢复	否	是
LLM 参与	停止后重新开始	错误信息返回 LLM
适用场景	明显错误、死循环	编译错误、类型错误
资源影响	浪费已使用的 Token	只额外消费重试 Token

第 6.5 节 Agent SDK 的中止与拦截对比

第 6.6 节 设计规范要点

1. **类型约束注入必须精确**：类型信息必须从实际项目中提取（不能靠 LLM 记忆），因为 TypeSys 每次生成都可能改变类型定义。
2. **编译器反馈必须结构化**：错误信息的格式必须统一（文件、行号、列号、错误代码、错误描述），方便 LLM 精确定位。
3. **重试必须有限制**：最大重试次数（建议 3 次），超过限制后降级处理（切换到更强的模型或请求人工介入）。
4. **拦截器必须分层解耦**：L1-L5 每层独立，某层失败不影响其他层运行，但 L3 编译失败必须阻止代码写入生产文件。
5. **不修改受保护区域**：TypeSys 生成文件区域为只读禁区。Copilot 必须识别这些区域并拒绝修改请求。
6. **提示词 + 外部约束互补**：提示词优化用于提升 LLM 的意图理解，编译器/类型系统/权限控制用于防止 LLM 的越界行为。前者有天花板 [Liu, Lin, Hewitt, et al., 2023]，后者才有确切保证。

第 6.7 节 设计哲学

编译器不是 AI 的对手，而是 AI 所欠缺的形式化能力 [Aho et al., 2006]。

强类型不是限制，而是将模糊的自然语言离散化为精确约束的桥梁 [Pierce, 2002]。

架构约束不是枷锁，而是在混沌中为 LLM 提供可靠地图的导航系统。

提示词优化有天花板 [Liu, Lin, Hewitt, et al., 2023]——编译器检查没有。

第 7 章

技术实施方案

第 7.1 节 开发语言方案研讨

本节从开发 *Copilot* 本身的角度，评估三种候选语言的适配性。核心评价标准：**该语言的原生能力是否能支撑 Copilot 五层拦截器的实现需求**——特别是 L3 编译检查（需要原生访问编译器 API）、L4 权限控制（需要进程/文件系统级操控）、以及各层之间的 Railway 管道组合。

开发效率排序：**F# > TypeScript > Python**。

第 7.1.1 节 F#：首选方案——全层原生适配

F# 是构建 Copilot 的**最自然选择**，因为它提供了 L1-L5 各层所需的**原生能力**：

1. **L3 编译检查（核心）**：[FSharp.Compiler.Service](#)（FCS）是 F# 编译器的程序化接口——可进行语法解析、类型检查、编译诊断提取。**无需子进程**：直接调用 `FSharpChecker.ParseAndCheckFileInProject()` 即可获得结构化错误信息 [Syme, Granicz, and Cisternino, 2007]。这是 TypeScript 或 Python 无法比拟的——它们要检查 F# 代码只能 `spawn("dotnet build")`，增加延迟和失败点
2. **L1 类型注入**：F# 的类型提供者（Type Provider）可在编译时读取

`Design-*.json` 或 `OrmTypes.fs`, 自动生成类型约束注入 L1 提示词片段——类型安全地桥接元数据与提示词

3. **L2-L5 管道组合**: Railway Oriented Programming (ROR) 是组合 $L1 \rightarrow L2 \rightarrow L3 \rightarrow L4 \rightarrow L5$ 的天然模式——每层返回 `Suc context` | `Fail error`, 失败自动短路并触发 L5 记录
4. **基础设施复用**: 直接引用 `Common/Util` 库 (`Bin.fs`、`Json.fs`、`Db/DbQuery.fs`), 复用日志、序列化、数据库
5. **单一可执行文件部署**: `dotnet publish -r win-x64 --self-contained` 编译为 ~50MB 单文件 `.exe`, 无需运行时

劣势与对策:

- LLM 对 F# 代码生成弱于 TS/Python——这恰恰是 Copilot 的价值点: 编译反馈循环弥补 LLM 的 F# 短板
- FCS 文档稀少——但 JCS TypeSys 的 `CodeRobotII.fs` 已有 FCS 成功先例

第 7.1.2 节 TypeScript: 次选方案——前端层原生、核心层受限

TypeScript 在 L1/L2/L5 (前端相关层) 有优势, 但在 L3 编译检查层有**结构性缺陷**:

1. **TypeScript Compiler API**: `ts.createSourceFile()` + `ts.createProgram()` 可对 TS 代码做 AST 解析和完整类型检查——但仅限于 TypeScript 代码。要检查 F# 代码必须跨进程调用
2. **前端同语言**: L5 监控面板 (Vue 3 Web UI) 与 L2 路由逻辑用同一语言, 消除序列化开销
3. **LLM 训练充分**: TS 是 LLM 训练数据中的主要语言, AI 生成的 TS 拦截逻辑比 F# 更可靠
4. **Bun compile**: `bun build --compile` 可打包为 ~40MB 单文件

结构性缺陷:

- **不能原生检查 F# 代码**: L3 的核心能力——F# 代码编译检查——TypeScript 无法原生实现, 只能 `spawn("dotnet build")`
- **运行时类型擦除**: 编译期类型检查无法延伸到运行时验证
- **Promise 异步模型**在拦截管道中增加复杂度

适用层：L1（ts-morph 解析 [OrmTypes.d.ts](#)）、L2（模型路由 HTTP 调用）、L4（Deno 文件系统沙箱）、L5（Vue 3 监控面板）。

第 7.1.3 节 Python：备选方案——仅适用于快速原型

Python 在 LLM 生态中拥有最丰富的库，但在构建 Copilot 时有**多项根本性不足**：

1. **LangChain**：成熟的 LLM 编排框架，L1/L2 原型可在数小时搭建
2. **LLM 训练最充分**：Python 是 LLM 训练数据中最多的语言
3. **修改即运行**：无编译步骤，迭代最快

根本性不足：

- **不能原生检查任何静态类型语言的代码**：Python 没有 FSharp.Compiler.Service 等价物——L3 编译检查唯一选择是子进程调用
- **弱类型**：运行时类型错误需 mypy --strict + pydantic 补救，增加代码量
- **GIL 限制并发性能**
- **部署体积大**：PyInstaller 打包 ~100MB+
- **异构通信成本**：F#/TS 项目引入 Python 组件需 HTTP 通信，每增加一个跨语言调用就增加一个失败点

适用场景：L1 提示词模板的快速实验验证（LangChain），确认方案后迁移到 F# 或 TypeScript。

第 7.1.4 节 方案对比与推荐

推荐策略：

1. **L3 编译检查核心：F# 独占**——FCS 是唯一能原生检查 F# 代码的选择，L3 是整个系统的价值核心，不可妥协
2. **L1 类型注入**：TypeScript（解析 TS 类型声明 + 生成提示词片段）或 F#（Type Provider 直接读取 F# 类型）。推荐 F#——同进程无序列化开销
3. **L2 模型路由**：TypeScript——HTTP 调用 + 与 L5 前端同语言
4. **L4 权限控制**：TypeScript（Deno）——成熟的文件系统权限模型

能力维度	F#	TypeScript	Python
F# 代码编译检查	FCS 原生	需 spawn 子进程	需 spawn 子进程
TS 代码编译检查	需 spawn 子进程	Compiler API	需 spawn 子进程
类型安全	编译期保证	编译期（运行擦除）	可选注解
ROR 管道组合	原生 >	需 Result<T,E> 库	需第三方库
与 JCS 基础设施集成	零成本	前端同语言	需跨语言通信
LLM 训练充分度	中	高	高
原型速度	中	中	快
部署体积	小（~50MB）	小（~40MB）	大（~100MB+）
L3 延迟	进程内（<10ms）	子进程（~500ms）	子进程（~500ms）

- 5. **L5 监控层**：TypeScript（Vue 3 前端 + HTTP API 后端），全栈 TypeScript
- 6. **快速原型**：Python（LangChain）仅用于 L1 提示词模板实验，验证后迁移到 F# 或 TypeScript

原则 7.1.1 (语言选型原则). 编译检查 (L3) 必须用 F#——因为只有 F# 能原生调用自己的编译器。不能用 Python 或 TypeScript 通过子进程绕道——子进程延迟（~500ms）乘以反馈循环的重试次数（平均 1.5 次），累积延迟使交互体验不可接受 [Shinn, Labash, and Gopinath, 2023]。

周边层（L1/L2/L4/L5）可用 TypeScript 加速开发——这些层不涉及 F# 编译器的内部调用，跨语言通信通过 HTTP/localhost 完成，延迟在可接受范围内。

开发效率：F# > TypeScript > Python。不是因为 F# 的语法更简洁，而是因为它对该任务有最强的原生支持。

第 7.2 节 AIO Avalonia 现有界面分析

Copilot 不应该是独立的工具——它应该嵌入到日常开发环境中。AIO（个人一体化桌面 IDE）使用 Avalonia UI 12.0.3 构建，是嵌入 Copilot 的**理想宿主**。

第 7.2.1 节 现有架构

AIO Avalonia 桌面应用采用 **FluentTheme** 风格，全部 UI 以 F# 代码构建（仅 `App.axaml` 一个 XAML 文件用于声明主题）：




图 7.1: AIO Avalonia 现有界面结构: DockPanel 主窗口 + LayoutGrid 三区布局

主窗口 (`MainWindow.axaml.fs:12--50`):

- **DockPanel**: 经典桌面应用布局——顶部菜单栏 + 工具栏，底部状态栏，中间为可替换的 `ContentControl`
- **MainMenu**: 文件/编辑/视图/AI/API/帮助——AI 菜单已有入口
- **MainStatus**: 实时状态栏，显示端口号、连接状态、操作提示

全局布局 (`Global.fs:24--27`):

```
1 let layout = LayoutGrid([| 1.0; 0.25 |], [| 0.15; 0.75 |])
2 let tabContainer = new TabContainer()
3 let console = new TextConsole(BufferSize = 500)
4 let rscMgr = new ResourceManager()
```

`LayoutGrid` 是 2 行 × 2 列的网格（行比 1:0.25，列比 0.15:0.75）：

- **列 0 (15%)**: `Resource Manager`——文件树（开发项目 + 文档项目 + 文件服务）
- **列 1 (75%，行 0, 80%)**: `TabContainer`——标签页容器（当前仅 `AiProg`）
- **列 1 (75%，行 1, 20%)**: `TextConsole`——底部控制台输出

AI 编程标签页 (`AiProgLayout.fs:85--117`):

- 行 0: 顶部面板——Provider 选择 (Gemini/DeepSeek) + 模型下拉 + 项目下拉
- 行 1: 按钮面板——全选/清空/删除/合并/创建提示
- 行 2: 附件标题 + 清空按钮
- 行 3: 附件区域 (WrapPanel 文件标签)
- 行 4: 聊天区 (左 70% ListBox + 右 30% 提示列表)
- 行 5: 底部输入区——多行 TextBox + 发送/高度切换按钮

关键观察: 当前 AiProg 标签页是**纯聊天式** AI 交互——用户输入消息 → LLM 返回文本 → 显示在聊天列表中。没有任何编译检查、类型约束、权限拦截——所有约束依赖模型本身的对齐训练 (RLHF) [Ouyang, Jeffrey Wu, Jiang, et al., 2022] 和提示词工程, 这正是 Copilot 要解决的问题。

第 7.2.2 节 现存的问题

1. **无编译反馈:** AiProg 生成的代码直接显示在聊天框, 没有语法检查、类型检查、编译验证——用户只能手动复制到 IDE 中测试
2. **无类型约束注入:** 没有从项目类型定义中提取类型信息注入到提示词中——LLM 凭记忆生成代码, 经常用错类型
3. **无权限边界:** 文件附件机制允许用户附加任意文件 (通过 Resource Manager 选中), 但没有写入权限管理——生成的代码写入哪里没有约束
4. **无监控统计:** 没有 Token 消耗追踪、编译成功率统计、重试次数记录——无法量化 AI 编程的效率
5. **没有拦截器面板:** 用户看不到 L1-L5 的运行状态——哪些规则被触发、哪些代码被拦截、成功率和失败原因全部不可见

第 7.3 节 Copilot 界面嵌入设计

本节提出将 Copilot 五层拦截器嵌入 AIO Avalonia 桌面的具体方案。

第 7.3.1 节 整体策略

不改变现有布局结构——在 AiProg 标签页内扩展，而非增加新模式。理由：

- 用户已有的工作流（选择项目 → 输入消息 → 查看回复）不变
- 新增功能通过**侧边栏** + **底部面板**提供，不中断核心交互
- 拦截器状态通过**非侵入式指示器**显示，避免信息过载

第 7.3.2 节 新布局设计




图 7.2: Copilot 嵌入 AiProg 后的新布局：五层拦截器左侧状态栏 + 类型约束/文件右侧面板 + 编译日志/Token 底部面板

第 7.3.3 节 界面效果预览



图 7.3: Copilot 主面板: 中央聊天区 + 左侧拦截器状态 + 右侧类型约束/文件面板



图 7.4: Copilot 配置面板：拦截器启停（L1-L5）+ 模型选择 + 权限白名单管理



图 7.5: Copilot 监控仪表盘：Token 消耗趋势 + 编译成功率曲线 + 重试分布 + 拦截器触发日志

第 7.3.4 节 布局详细规格

行定义（7 行，在现有 6 行基础上扩展）：

1. **行 0：顶部面板（Auto）** —— 在现有 Provider/Model/Project 选择器后新增：[Copilot 开关] 切换按钮（启用/禁用拦截器），五层拦截器状态指示灯（L1 L2 L3 L4 L5，绿/黄/红）
2. **行 1：按钮面板（Auto）** —— 同现有，增加 [编译检查当前] 按钮
3. **行 2：附件标题（Auto）** —— 同现有
4. **行 3：附件区域（Auto）** —— 同现有
5. **行 4：主内容区（Star, 3 列）** ——
 - **列 0（12%）**：拦截器状态侧边栏——5 个状态面板（L1-L5），每层显示状态图标 + 统计数
 - **列 1（58%）**：中央聊天区——在现有 ListBox 基础上，每条消息附加编译状态标签
 - **列 2（30%）**：右侧信息面板——上半部显示当前注入的类型约束，下半部显示生成文件列表（尝试次数 + 编译结果）
6. **行 5：编译日志面板（Star, 轻量）** —— 显示最近一次编译的完整错误输出（结构化），带语法高亮
7. **行 6：底部输入 + Token 指示（Auto）** —— 左侧输入区（同现有），右侧 Token 用量仪表

第 7.3.5 节 新增 UI 组件

拦截器状态指示器（InterceptorStatusBar）：

- 五个圆角矩形（L1-L5），每个含状态指示灯（绿/黄/红/灰）和简短统计
- 点击某层展开详情——L3 显示最近编译日志，L5 显示今日 Token 消耗曲线
- 实现：UserControl，绑定到 InterceptorState record

类型约束面板（TypeConstraintPanel）：

- 显示当前注入到提示词的类型定义（只读）
- 来源标注（自动从 TypeSys / 手动 / LLM 推断）
- 实现：ContentControl + Markdown 渲染

编译日志面板 (CompileLogPanel):

- 显示最近一次编译的完整输出，带语法高亮（错误红色、警告黄色）
- 支持滚动查看所有错误
- 实现：TextBlock + 等宽字体 + 语法高亮

Token 仪表 (TokenGauge):

- 圆形进度环或横向进度条，显示今日 Token 使用量 / 预算
- 鼠标悬停显示详细分解（按模型、按任务类型）
- 实现：Canvas 自绘，绑定到 TokenStats record

第 7.3.6 节 F# 代码实现方案

新增控件通过 F# 代码构建（与现有 Avalonia UI 一致），以下为关键类型的 F# 伪代码：

```
1 // InterceptorState.fs — 五层拦截器状态类型
2 type InterceptorStatus = Active | Blocked | Error | Disabled
3
4 type InterceptorState = {
5     L1_TypeInjection: InterceptorStatus
6     L1_BlockedCount: int
7     L2_ModelRoute: InterceptorStatus
8     L2_CurrentModel: string
9     L3_CompiledCheck: InterceptorStatus
10    L3_PassRate: float
11    L3_LastError: string option
12    L4_Permission: InterceptorStatus
13    L4_BlockedOps: int
14    L5_Monitor: InterceptorStatus
15    L5_TokenUsed: int64
16    L5_TokenBudget: int64
17 }
18
19 // 新控件: compileLogPanel
20 let compileLogPanel = TextBlock(
21     FontFamily = "Consolas",
22     FontSize = 12.0,
23     TextWrapping = TextWrapping.Wrap,
24     IsVisible = false // 仅在编译失败时显示
25 )
```

集成位置	现有代码	改动
顶部面板	AiProgLayout.fs:17--35	+Copilot 开关 + 状态指示灯
主内容区	AiProgLayout.fs:99--108	2 列 → 3 列, +左右面板
聊天消息	ChatMsg.fs	+编译状态标签 (每条消息)
Resource Manager	ResourceManager.fs:31--208	已有文件选择, 无需改动

第 7.3.7 节 与现有代码的集成点

关键原则:

- 1. **最小侵入**: 现有聊天式交互完全保留——Copilot 的拦截器在后台运行, 状态通过非侵入式指示器呈现
- 2. **渐进增强**: 用户可以先 “关闭 Copilot” (回退到原始 AiProg 行为), 再逐步启用各层拦截器
- 3. **编译反馈可视化**: LLM 生成代码后, 编译结果 (通过/失败/错误详情) 直接显示在聊天消息旁边, 而非隐藏在日志中
- 4. **类型约束透明**: 右侧面板实时显示当前注入的类型信息——用户可以检查 LLM 收到的提示词中包含了哪些类型定义

原则 7.3.1 (界面设计原则). *Copilot* 的界面应该是信息透明 + 非侵入。拦截器在后台运行, 不打断用户与 LLM 的对话流——但状态指示灯和编译标签让用户始终知道系统在做**什么**。

这不同于 *CodeBuddy* 的 “审计日志事后查看” 模式——*Copilot* 的监控是**实时**的、嵌入在交互界面中的 [Q. Wu, Bansal, Zhang, et al., 2023]。

第 7.3.8 节 从静态日志到动态时光机 (Timeline Shift)

当 MCTS (蒙特卡洛树搜索) 引入后, 代码生成不再是线性的——多个分支在不同的编译得分下同时探索, 各自沿着独立的路径演化。用户在 Avalonia 界面上如果只看到滚动的文字日志, 会产生极大的认知过载: 无法区分哪个分支被采纳、哪个被剪枝、当前的生成走到了搜索树的第几层。

设计方案: 将编译日志面板升级为**动态时光机** (*Timeline Shift*):

- **时间轴导航**: 底部编译日志不再是 “最近一次” 的静态快照, 而是可滚动的**时间轴**——用户可以在搜索树的任何历史节点之间跳转

- **分支对比视图**：当 MCTS 采样 3 个分支时，用户可以在编译日志面板中并排查看各分支的编译结果和代码差异
- **回滚按钮**：用户点击被剪枝的节点 → 右侧编辑器加载该节点的代码 → 可以在该节点基础上手动修改并重新提交

第 7.3.9 节 树状分支图控件（Tree Graph Control）

在中央面板引入一个树状分支图控件，实时渲染 MCTS 的搜索拓扑：

- **红色枯枝**：被 FCS 剪枝（编译失败）的节点——用户可以看到系统为什么拒绝了这个分支（悬停显示编译错误详情）
- **黄色闪烁**：当前正在探索的节点（LLM 正在采样/编译器正在检查）
- **绿色高亮**：最终采纳的代码路径——从根节点到采纳节点的完整路径以粗绿线连接
- **UCT 分数标注**：每个节点旁边显示该节点的 UCT 值 w_i/n_i ，帮助用户理解系统的决策依据
- **点击回溯**：用户可以点击任意历史节点（哪怕是失败节点），右侧 [AvaloniaEdit](#) 编辑器加载该节点当时的代码片段




图 7.6: MCTS 搜索树可视化：绿色=采纳路径，黄色=探索中，红色=被剪枝。每条边标注 UCT 得分或编译结果。

控件规格：

- **实现方式**：Avalonia Canvas 自绘（SkiaSharp 渲染）——利用现有的

Direct2D 绑定点，节点和边用贝塞尔曲线连接

- **数据绑定**：MctsState record 包含节点列表、边列表、当前活跃节点 ID、剪枝原因字典
- **交互**：节点点击 → 触发生成当前节点代码视图（右侧编辑器更新）+ 编译日志定位到该节点的编译输出
- **性能**：搜索树节点数通常 <100（3 分支 × 3 层深），Canvas 渲染无性能问题

第 7.3.10 节 UI 扩展对架构的影响

引入时光机和树状图后，Copilot 界面的信息密度大幅上升。但这**不是增加复杂性**——而是将原本隐藏的搜索过程可视化。用户从“不知道 Agent 在做什么”升级为“可以追溯 Agent 的每一个决策”，这正是复盘中所要求的**可控感**。

原则 7.3.2 (可控感是信任的基础). 当 MCTS 树状分支图控件让用户看到 Agent 的每一项决策依据 (UCT 得分、编译结果、剪枝原因)，用户就可以：

- 回溯到任何历史节点，手动接管
- 理解为什么某个分支被剪枝了
- 对最终采纳的路径有充分的信心

可控感 = Copilot 从“黑箱”到“透明决策系统”的本质转变。

第 7.4 节 临时文件管理

为避免污染项目目录，代码生成和编译检查应在临时目录进行：

```
1 C:/Dev/.codebuddy/temp/AIO/codegen/{guid}/  
2 attempt-1.fs (* 第 1 次尝试 *)  
3 attempt-2.fs (* 第 2 次尝试 *)  
4 attempt-3.fs (* 第 3 次尝试 *)  
5 ...
```

只有编译通过的代码才从临时目录复制到项目源码目录。这与 TypeSys 的离线生成理念一致——隔离环境，防止污染。

第 7.5 节 错误信息提取

编译器的错误信息需要结构化提取，以便 LLM 理解：

```
1 {  
2   "success": false,  
3   "errors": [  
4     {  
5       "file": "temp.fs",  
6       "line": 10,  
7       "column": 5,  
8       "message": "期望类型，但得到int64 string",  
9       "code": "FS0001"  
10    }  
11  ]  
12 }
```

第 7.6 节 反馈提示词设计

将错误信息反馈给 LLM 时，提示词应包含 [Shinn, Labash, and Gopinath, 2023; Z. Wang, Mao, Jason Wu, et al., 2023]：

1. 原始用户需求
2. 生成的代码（失败版本）
3. 编译错误信息（结构化 JSON）
4. 修复指示（例如 “请修复第 10 行的类型错误：期望 int64 但得到 string”）

第 7.7 节 完整执行流程

第 7.8 节 模型选择策略

基于 Scenario 枚举的模型映射（参考 jCQT.AI.Model 设计）：




图 7.7: 完整执行流程: L1 提取 → L2 生成 → L3 编译检查 → 失败反馈重试 → 成功则 L4 权限检查写入 → L5 记录

场景	模型
代码生成	qwen2.5-coder:14b（本地 Ollama）
推理/分析	deepseek-r1:14b
通用对话	qwen2.5:14b
文档生成	gemma3:12b
视觉/图表	qwen3-vl:8b

第 7.9 节 权限白名单体系

执行层的权限控制采用正列表（Allowlist）策略：

- **允许写入**：临时目录（temp/）、用户指定的项目源码目录
- **只读**：TypeSys 生成文件、项目配置文件、数据库
- **禁止**：rm -rf、format、force push、系统目录
- **需确认**：curl/wget、sudo/chmod、SSH 命令
- **进程保护**：taskkill 前必须 tasklist | findstr <PID> 确认身份，仅 kill dotnet/Server/node/bun

第 7.10 节 实施路线图

1. **第一阶段**：实现 L3 后处理拦截器（编译检查 + 错误提取 + 反馈重生）——用 FSharp.Compiler.Service + Railway Oriented Programming
2. **第二阶段**：实现 L1 提示词预处理器（TypeSys 类型信息提取 + 危险操

- 作检测)——用 F# Type Provider 直接读取 `OrmTypes.fs`
3. **第三阶段**: 实现 L4 执行层权限控制 (文件白名单 + 命令白名单 + 进程保护)——用 TypeScript (Deno/Bun 沙箱)
 4. **第四阶段**: AIO 桌面界面集成——AiProg 标签页扩展 (拦截器状态栏 + 编译日志 + Token 仪表)——F# Avalonia 代码 + 新控件
 5. **第五阶段**: 实现 L5 监控与反馈层 (全链路日志 + 实时统计 + 自动调整)——TypeScript + Vue 3 前端面板
 6. **第六阶段**: 实现 L2 模型路由层 (Scenario 映射 + 模型选择)——TypeScript (LangChain 快速原型后迁移到 TS)

原则 7.10.1 (资源效率原则). 监控不是“看看”，而是**自动调整** [Q. Wu, Bansal, Zhang, et al., 2023]。当编译成功率低于阈值时，系统应该**自动增强** 类型约束注入或切换到更擅长的模型，而不是等待人工介入 [Shinn, Labash, and Gopinath, 2023]。

第 8 章

类型论

第 8.0.1 节 从简单类型到依赖类型

绝大多数程序员接触的“类型”止步于简单类型系统（Simple Type System）—— int、string、bool、泛型、接口。这是第一层理解：**类型 = 数据形状的约束**。

但数理逻辑意义上的类型论远不止于此。在 Martin-Löf 类型论（MLTT）中，类型是命题，程序是证明。依赖类型（Dependent Types）允许类型依赖于值：

```
1 (* 依赖类型的核心思想：类型可以依赖值 *)
2 // 简单类型：长度为 n 的数组是 List<int>
3 // 依赖类型：长度为 n 的数组是 Vec n int
4 // 其中 n 是一个值，而非类型参数
```

定义 8.0.1 (命题即类型 (Curry-Howard 对应)) . *Curry-Howard 同构*揭示了程序与证明之间的深层对偶关系：

- 类型 = 逻辑命题
- 程序 = 该命题的构造性证明
- 类型检查 = 证明验证

这意味着：一个类型正确的程序，就是一个数学证明。

这一视角将程序设计从“写出能运行的代码”提升为“写出可验证的规约”。

第 8.0.2 节 国内类型论研究的四层金字塔

类型论在国内的分布极不均衡。根据一项调查 [JackZhu2026TypeTheory], 可以清晰地划分为四个层次:

层级	人群特征	规模与特点
第一层	普通程序员, 仅了解简单类型系统 (Java/C++泛型)	人数极多, 但与数理逻辑中类型论不是一回事
第二层	能使用证明助手 (Lean/Agda/Coq) 进行基础形式化	规模不大 (几百人), 对元理解较浅
第三层	真正理解类型论元理论, 可进行研究	人数极少 (全国几十人), 集中在少数高校 (中大/复旦/北中科院)
第四层	最大缺口: 既精通类型论元理论, 又懂工程/多物理场/算子谱	极其稀缺 , 类型论与工程圈严重脱节

核心观察: 国内真正吃透依赖类型论的人非常少, 属于极小的小众圈层。[JackZhu2026TypeTheory]

第 8.0.3 节 工程师为什么要学依赖类型论?

工程师学习依赖类型论, 不是为了在下一行代码里用它, 而是为了掌握一种能够描述“代码规格”本身的元语言。

原则 8.0.1 (工程师的元能力). 依赖类型论让你对程序的理解, 从“这段代码能跑”提升到“这段代码为什么必然正确”。

维度	常规编程语言	依赖类型论
核心任务	编写程序, 告诉计算机“如何做”	编写证明, 告诉计算机“此”
类型的作用	作为接口, 约束数据的形状	作为规格, 描述数据的
错误发现	通过测试来发现错误	通过类型检查来排除类别
验证时机	主要在运行时 (通过测试)	主要在编译时 (通过证
文档效果	代码与文档可能不一致	代码即文档, 类型即规

依赖类型论对工程师的核心价值体现在三个层面:

1. **获得“编译时正确性”的超能力：**在未来，处理核心算法（加密协议、并发锁、内存安全）时，依赖类型可以让你用数学证明来取代部分单元测试，从根源上杜绝整类 bug。
2. **理解下一代工程工具的逻辑：**形式化验证正在逐步工具化。像 TLA+（分布式系统）、Rust 的借用检查器、PyTorch 的 torch.jit.script，其底层逻辑都与“约束求解”和“程序逻辑”有关。依赖类型论是理解这些工具背后原理的“第一性原理”。
3. **打通跨学科协作的语言壁垒：**当你和数学家、物理学家讨论一个物理场（如“一个无散度的矢量场”）时，依赖类型提供了一种精确的、可计算的交流语言，使得规格本身就可以被代码校验。

第 8.0.4 节 依赖类型论在本项目中的映射

本手册的整个设计——JCS 的确定性生成、FCS 的编译检查、MCTS 的搜索树、红蓝对抗的靶场化——都可以看作依赖类型论思想的工程投影：

- **TypeSys / Design-*.json** = 类型论中的“语境”（Context）——所有类型定义的唯一真相源
- **FSharp.Compiler.Service** = 类型检查器——验证代码是否符合规约
- **JCS 的只读 VFS 钩子** = 类型论中的“禁止逃逸”——生成代码不可修改
- **MCTS 搜索树 + UCT 剪枝** = 类型推导中的“搜索空间剪枝”——用编译器作为奖励函数
- **红蓝对抗的靶场化** = 类型论中的“反例构造”——红军生成测试脚本作为形式化反证

原则 8.0.2 (从类型论到工程)。 本手册试图证明：**依赖类型论不仅仅是理论研究的前沿，它已经以“工程化约束”的形式进入了工业级代码生成系统。**

Copilot 的 L3 编译器反馈循环，本质上是一个将 LLM 的概率输出通过类型系统校验收敛为确定性输出的闭环。这正是依赖类型论思想在工程中的落地形态。

类型论不是象牙塔里的数学游戏——
它是将模糊意图转化为精确约束的工程语言。

提示词有天花板，类型检查没有。[Liu, Lin, Hewitt, et al.,

2023]

第 9 章

前沿研究与系统演进

前六章讨论的是 Copilot 的“现在”——五层拦截器、编译器反馈、类型约束注入。本章将视野拉高到战略层面：从前沿研究、复杂系统设计和分布式系统演进的角度，探讨 Copilot 的下一步——**多智能体动力学 (Multi-Agent Dynamics)**、**形式化验证 (Formal Verification)** 以及**环境底座 (Environment Fabric)**。

仅停留在“写代码和改错”的微观视角已经不够——当系统复杂度超过 LLM Agent 的单线程处理能力时，必须引入多 Agent 协作、符号化推理和沙箱化执行等更高层次的机制。

第 9.1 节 MCP 够不够——从静态协议到全状态守卫网关

MCP (Model Context Protocol) 作为“通信标准”是足够的，但作为“控制安全边界”远远不够 [Anthropic, 2024]。

第 9.1.1 节 MCP 的贡献：连接性与语义对齐

前沿研究（*AutoGen* [Q. Wu, Bansal, Zhang, et al., 2023]、*LangGraph*、以及 Anthropic 自身的 MCP 演进）表明，MCP 解决的是**连接性（Connectivity）**和**语义对齐（Semantic Alignment）**的问题——它让大模型能用标准协议去发现工具、调用工具并读取上下文。Agent 不再需要理解 HTTP/RPC/文件系统的底层细节，只需要知道“有什么工具”和“工具怎么用”。

第 9.1.2 节 局限性：静态性

MCP 的控制通常是**静态的**——参数校验、ACL 白名单、工具级权限。这些约束在**定义时**就已经写死，无法感知运行时的**系统状态**。

典型的失败场景——第一章复盘中的 PID 误杀事故：taskkill 工具在 MCP 协议层是合法的——参数格式符合标准规范，目标进程确实存在，令牌（Token）通过了 ACL 校验。但这一行为的破坏性（杀掉了 CodeBuddy CN 隧道进程，导致 IDE 崩溃），是 MCP 在工具网关层面**无法感知**的。

MCP 缺少的是对系统状态（State）深度上下文的感知能力。它不知道：

- 当前进程的**身份**——这个 PID 是 IDE 进程还是开发进程
- 文件树的**敏感区域**——哪个目录改了会影响整个系统的稳定性
- 网络拓扑的**依赖关系**——哪个端口断了会导致服务完全不可用

第 9.1.3 节 演进方向：全状态守卫网关（Stateful Guardrails）

前沿方向不是让工具本身变聪明，而是将 MCP 工具暴露在一个**虚拟化的操作系统沙箱**中——如 WASM 或轻量级 microVM。

定义 9.1.1 (数字孪生预执行). Agent 发出的每一条 MCP 指令，在被真正执行前，要在沙箱环境的**数字孪生（Digital Twin）**中试运行，捕捉其对文件树、进程树和网络拓扑的改变，通过静态和动态策略组合阻断越界行为。

这一机制将 Copilot 的 L4 执行层从“定义时白名单”升级为“运行时状态

感知”：

$$L4_{\text{new}} = L4_{\text{static}} \oplus \text{StatefulGuard}$$

其中 StatefulGuard 维护：

1. 进程身份图谱：PID → 所属服务（IDE / Server / Agent / 用户）
2. 文件影响域：写操作 → 波及的模块（TypeSys 生成区 / 配置 / 源码）
3. 网络依赖图：端口 → 服务 → 上游消费者（CF Tunnel / 前端 / API）

第 9.2 节 反馈循环的进阶——从线性反思到 MCTS 搜索树

第 9.2.1 节 当前 Loop 的天花板

目前手册中描述的 L3 编译反馈循环——“编译失败 → 结构化错误 → 反馈 LLM → 重生成”——是一种**单线演进（Linear Rollout）** [Shinn, Labash, and Gopinath, 2023; Z. Wang, Mao, Jason Wu, et al., 2023]。

它的核心问题是**局部最优陷阱**：当 F# 类型推导极其复杂时，LLM 在第二步改错了代码，第三步会在错的基础上继续猜，**在概率空间的死胡同中越走越远**。这是所有单线反思式 Agent（包括 *Reflexion*）的共性缺陷。

第 9.2.2 节 前沿方案：MCTS 代码生成

结合前沿研究——*DeepSeek-R1* 的强化学习与搜索范式、OpenAI *o1* 的推理链探索，以及学术界的 *Tree of Thoughts (ToT)* [Yao, Yu, et al., 2024]——代码生成的 Loop 应该从**线性循环**升级为**蒙特卡洛树搜索循环（MCTS Loop）**：

1. **分支采样（Branching）**：LLM 针对一个用户需求生成 3 个不同的候选代码片段，各采样不同的概率分支（温度 $T = 0.8$ 、top-p 变化）
2. **编译器剪枝（Pruning）**：利用 `FSharp.Compiler.Service`（FCS）进程内编译 对 3 个分支进行快速打分：
 - 编译完全失败的分支直接剪枝（得分 = 0）
 - 通过但类型推导不精确的得部分分（得分 = 0.5）

- 类型推导最接近正确的作为高分节点继续向下探索
- 3. **回溯 (Backtracking)**: 当某一条修复路径重试 2 次依然死锁时, Loop 必须具备回滚能力——退回到上一个编译正常的代码 AST 节点, 换一个思路重新生成
- 4. **UCT 节点选择**: 使用 UCT (Upper Confidence Bound for Trees) 公式在探索与利用之间取得平衡:

$$UCT(v_i) = \frac{w_i}{n_i} + C\sqrt{\frac{\ln N}{n_i}}$$

其中 w_i 是该节点的编译通过次数, n_i 是访问次数, N 是父节点访问次数, C 是探索常数

原则 9.2.1 (真正的循环不是原地打转). 线性反思是在一条死胡同里反复尝试——改错了继续改, 改对了也不知道为什么对。

MCTS 循环是在树状空间中搜索——有多条路径可选, 有编译器作为客观评判, 有回溯机制防止死锁, 有探索-利用平衡防止过早收敛。

真正的 Loop 不是原地打转, 而是树状空间的搜索。

第 9.2.3 节 工程实现路径

在 F# + JCS 技术栈下:

1. FGS 的 ParseAndCheckFileInProject 返回结构化诊断——可直接映射到 MCTS 节点的得分函数
2. F# 的不可变数据结构 (Record/Discriminated Union) 天然适合表示搜索树的节点和状态
3. 并行采样 3 个分支可借助 Async.Parallel + Ollama 本地多模型并发
4. UCT 计算是纯函数——适合 F# 的 $>$ 管道组合

第 9.2.4 节 确定性奖励函数 (Deterministic Reward Function)

MCTS 的核心在于 UCT 公式中的价值评估 (Value) 项 w_i ——它决定了一个节点是否值得继续探索。绝对不能让另一个 LLM 来盲目给代码打分——这

是用概率系统评估概率系统，误差在反馈循环中指数放大。

必须建立一个由静态指标组成的复合奖励函数：

$$R = w_1 \cdot \mathbb{I}(\text{CompilePass}) + w_2 \cdot \mathbb{I}(\text{TypeSysMatch}) - w_3 \cdot \text{CodeSize} - w_4 \cdot \text{WarningCount}$$

其中各项定义：

- $\mathbb{I}(\text{CompilePass})$ = FCS 编译通过得 1 分，否则 0 分。这是硬门槛——编译失败的节点 R 自动归零（或被赋负分）
- $\mathbb{I}(\text{TypeSysMatch})$ = 生成的代码完美契合 JCS 契约得 1 分。包括：使用了正确的 `T__U` 命名、Railway 模式、API 字典分发
- CodeSize = 代码行数（或 AST 节点数）的归一化值。短代码偏好——给定同样的功能，更短的代码得分更高
- WarningCount = 编译器警告数量。严格模式：开启 `warnaserror:76`——不详尽的模式匹配直接视为编译失败，不计入警告而直接判 0

权重建议： $w_1 = 50, w_2 = 30, w_3 = 1, w_4 = 10$ 。编译通过是最重要的（50 分），JCS 契约契合次之（30 分），代码长度轻微惩罚（短代码在调试时更易追溯），每个警告扣 10 分。

原则 9.2.2 (不要用 LLM 评判 LLM)。奖励函数必须完全由客观的、可重现的静态指标构成：FCS 编译结果、类型检查报告、代码度量。

任何引入另一个 LLM 来“评估代码质量”的做法，都是在概率系统中叠加概率判断——最终的误差不是线性累加，而是指数放大。

编译器不会骗你。LLM 会。

第 9.3 节 多 Agent 竞争与协同

第 9.3.1 节 单一 Agent 的失效模式

第一章复盘揭示的子 agent 虚假信息事故——code-explorer 报告文件存在但实际不存在，导致主 Agent 花 30 分钟诊断错误方向——是**单一全能 Agent 必然失效**的典型案例 [Kadavath, Conerly, Askell, et al., 2022]。

在没有监督的情况下，LLM Agent 会“串通欺骗”或“选择性失明”：子 agent 为了满足主 agent 的预期，可能返回一个**看似合理但完全错误**的答案，而主 agent 没有能力验证这个答案的真实性。

第 9.3.2 节 方案 A：红蓝对抗 (Competitive Red-Teaming)

引入竞争机制，而非协作机制：

定义 9.3.1 (红蓝对抗). 不要只让一个 Agent 写代码、另一个 Agent 看。

- **蓝军 (Generator Agent)**: 负责根据需求和 JCS 元数据快速编写业务代码。其考核指标是**编译通过率**和**业务逻辑正确性**。
- **红军 (Critic/Hacker Agent)**: 唯一考核指标是**找出蓝军代码的漏洞、边界条件缺失 或违反 ROP 模式的地方**。它不负责写代码，只负责构造“能够让蓝军编译失败 或业务测试失败的 Edge Case”。

纳什均衡: 这种竞争会逼迫蓝军在 MCTS 循环中不断提升代码健壮性，直到红军无法找到漏洞——此时系统达到**博弈均衡**，代码质量远高于单一 Agent 的输出。

第 9.3.3 节 方案 B：多视角共识 (Multi-Perspective Consensus)

针对高风险操作——部署白名单匹配、权限变更、生产环境写入——引入三个独立子 Agent (不同基座模型或不同 prompt)：

1. 每个 Agent 在完全隔离的链条下独立执行探测: Agent_A 检查端口可用性, Agent_B 检查 HTTP 响应状态, Agent_C 检查 Cloudflare Tunnel 状态
2. **投票共识**: 只有当至少两个 Agent 对同一执行结果做出相同的客观事实判断 (例如: 独立探测并一致确认端口可用、业务返回 200) 时, 主 Agent 才采信该结果
3. 这直接解决了子 Agent 返回虚假信息的问题—— **让谎言在多 Agent 共识中暴露出来**

原则 9.3.1 (多样性是安全的基石). 单一 Agent 的可靠性上限 = 该 Agent 模型的幻觉率下限。

多 Agent 系统的可靠性 = $1 - \prod_{i=1}^n P(\text{Agent}_i \text{ 同时出错})$

三个独立 Agent (不同基座模型) 同时犯相同错误的概率 远低于单一 Agent 的幻觉概率。

这就是为什么需要多 Agent —— 不是因为一个不够快, 而是因为一个不够可靠。

第 9.3.4 节 工程考量

1. **经济性**: 红蓝对抗 + 多视角共识会增加 2-3 倍的 Token 消耗—— 但相比生产事故 (端口误配导致 16 小时宕机), 这笔投资是值得的
2. **选择性启用**: 仅在 L4 高风险操作 (taskkill、systemctl restart、git push) 时启用共识投票
3. **红蓝对抗适用场景**: 代码生成阶段 (L3), 而非所有 Agent 交互
4. **本地多模型优势**: Ollama 可同时加载多个模型 (qwen2.5-coder:14b 蓝军 + deepseek-r1:14b 红军), 无需额外 API 费用

第 9.3.5 节 红蓝对抗的靶场化 (Sandboxed Range)

红蓝对抗不能停留在 “红军口头指出蓝军的漏洞” —— 这仍然是 LLM 评估 LLM 的模糊模式。必须将对靶场化: 红军的输出自动转化为可执行的自动化测试。

定义 9.3.2 (靶场化对抗). *Hacker Agent* (红军) 构造边界条件时, 其输出

不是文本质疑，而是可执行的 Fuchu 或 Expecto 自动化单元测试脚本。

Generator Agent（蓝军）生成的代码必须在这组临时生成的测试用例中跑通，才能将最终奖励的 $\mathbb{I}(\text{TypeSysMatch})$ 权重从 30 提升到 60（最高信任级）。

```
1 (* 红军自动生成的 Fuchu 测试脚本示例 *)
2 [<Test>]
3 let 边界条件: 空输入列表处理`` =
4     let result = processUser []
5     Assert.Equal("对空输入应返回 Ok []", Ok [], result)
6
7 [<Test>]
8 let 边界条件: 重复`` ID 的去重`` =
9     let input = [{Id=1L; Name="A"}; {Id=1L; Name="A"}]
10    match processUser input with
11    | Ok [x] -> Assert.Equal("重复应去重 ID", 1L, x.Id)
12    | _ -> Assert.Fail ("应返回去重后列表")
13
14 [<Test>]
15 let ``ROR 模式: 异常不得外泄`` =
16     // 构造极端输入验证 Railway 模式正确性
17     let result = processUser [makeInvalidUser()]
18     match result with
19     | Fail _ -> () // \docSuccess ROR 正确将异常捕获为 Fail
20     | Suc _ -> Assert.Fail ("异常应被捕获，不应直接返回 Suc")
```

靶场化的关键设计：

1. **测试即边界条件**：红军不输出“你应该检查空输入”——而是直接输出测试空输入的 Fuchu/Expecto 代码
2. **编译即第一关**：红军生成的测试脚本必须自身能编译（另一层 FCS 检查），否则视为无效边界条件
3. **蓝军必须跑通测试**：蓝军的代码 + 红军的测试 → dotnet test → 全部通过 → 蓝军获得最高信任权重 60
4. **测试可再生**：每次对抗的测试脚本保存在临时目录中，可以在后续会话中复用

原则 9.3.2 (从模糊对抗到形式化验证)．红蓝对抗的靶场化将这个流程从概率领域拉入形式化领域：

- 红军不再说“你的代码有漏洞”（概率判断）→ 而是构造了一个实际失败的测试
- 蓝军不再说“我修复了”（概率输出）→ 而是通过了红军的全部测试
- 裁判不再是 LLM → 而是编译器和测试框架

概率性的 LLM 被彻底锁死在形式化验证的闭环中——编译通过 + 测试通过 + 类型匹配 = 代码高度可信。

第 9.4 节 神经符号系统——代码语义的图嵌入与形式化验证

第三章指出 LLM 与 JCS 的核心对立：LLM 在连续概率空间操作，编译器在离散确定空间操作。前沿 AI 研究最核心的方向之一就是**神经符号 AI (Neuro-Symbolic AI)**——将深度学习的联想能力 (Neuro) 与人类的形式化逻辑推理、图论、符号演算 (Symbolic) 完美结合。

本手册的核心主张——编译器和类型系统是 LLM 的外部约束——本质上就是一种朴素的神经符号架构：LLM 负责神经端（生成代码），编译器负责符号端（验证代码）。但要真正解决 LLM 代码生成的系统性缺陷，必须进一步深化这一架构。

第 9.4.1 节 代码语义的图嵌入化 (Graph-Based Grounding)

当前 L1 类型约束注入仅将类型定义作为**文本 (Tokens)** 塞给 LLM。这在简单项目中有帮助，但在 JCS 体系的真实规模下远远不够——12 个项目配置、16 个数据库表、复杂的文件依赖关系无法压缩到几千 tokens 的提示词中。

方案：用 FCS 将整个项目的架构实时构建成为一张**代码语义依赖图 (Code Dependency Knowledge Graph)**：

- **节点：**模块 (Server、BizLogics、Shared、Common)、类型定义 (T__User、T__Project)、API handler (api__h 字典条目)
- **边：**
 - 引用边 (Server → BizLogics → Shared → Common)
 - 类型依赖边 (getUser → T__User → Id: int64)
 - API 调用边 (前端 postSignin → 后端 signin__h)
- **权重：**边的权重反映依赖的紧密度 (直接引用 > 间接引用 > 类型兼容)

这张图在 LLM 每次代码生成时动态构建——不是静态文档，而是代码库当前状态的实时快照。LLM 生成代码时，Copilot 从图中提取**最小相关子图** (仅

包含目标类型及其直接依赖), 作为结构化上下文注入到 L1 提示词中——而非全部类型定义的文本堆砌。

第 9.4.2 节 符号约束求解——SMT Solver 介入

当 Agent 想要改写某个关键业务逻辑时, 靠 LLM 自己去“思考”影响范围是不够的——它可能遗漏跨文件的类型依赖、Railway 管道断裂点、或 TypeSys 生成文件的覆盖冲突。

方案: 引入 SMT (Satisfiability Modulo Theories) 求解器 作为形式化验证引擎 [Moura and Bjørner, 2008]:

1. **影响域计算:** 通过代码语义图的图算法, 计算一次改动波及的**影响域 (Blast Radius)** —— 所有直接或间接依赖被修改类型/函数的代码位置
2. **符号约束提取:** 将影响域内的类型约束 (字段类型、管道签名、模式匹配完备性) 转化为 SMT 可求解的逻辑公式
3. **可满足性判定:** 将 LLM 生成的候选代码作为约束条件输入 Z3 求解器, 判定:
 - **SAT** (可满足): 候选代码在符号层面与现有类型系统一致
 - **UNSAT** (不可满足): 候选代码存在类型冲突或模式不匹配
4. **反例生成:** UNSAT 时, Z3 可生成一个具体的反例向量 (哪个类型、哪个字段、哪个约束被违反), 反馈给 LLM 作为精确的修复指令

原则 9.4.1 (神经符号分工). 让大模型负责提出猜想 (生成代码), 让形式化符号系统负责证明 (通过架构规约与图逻辑确保万无一失)。

LLM 的强项是**联想**——从自然语言需求映射到代码结构。符号系统的强项是**验证**——判定候选方案是否与现有约束系统一致。

两者结合 = 可以提出猜想 + 可以验证猜想 = 真正可靠的 AI 辅助编程。

第 9.4.3 节 工程现实与渐进路径

SMT 求解器的集成是长期目标 (~6-12 个月)。近期的可落地步骤:

1. **第一阶段 (当前):** FCS 编译检查 + 类型错误提取 (§ 4)

- 2. **第二阶段 (3 个月):** 代码语义图构建—— FCS 遍历项目 AST, 构建依赖图, 用于 L1 智能上下文提取
- 3. **第三阶段 (6 个月):** MCTS 循环—— 用 FCS 编译结果作为得分函数, 并行采样多分支代码
- 4. **第四阶段 (9 个月):** 红蓝对抗 Agent—— 蓝军 (生成) + 红军 (审查), 在 MCTS 框架内协作
- 5. **第五阶段 (12+ 个月):** Z3 集成—— 符号约束求解作为 L3 编译检查的增强层

第 9.5 节 系统演进战略总图

将以上所有高级讨论浓缩为 Copilot 的五层升级版架构:




图 9.1: Copilot 演进架构: L1 符号化剪切 → L2 MCTS 搜索树 → L3 树状循环 → L4 影子运行时 → L5 全链路审计

原则 9.5.1 (演进原则). 在 *F# + TypeScript + JCS* 的技术栈下, 最先落地的应该是 **MCTS 搜索树 (L2 升级)** 和 **代码语义图 (L1 升级)** —— 因为 *FCS* 已经提供了编译得分函数, *JCS* 的 *Design.json* 已经提供了结构化的类型知识图谱, 这两个基础设施已经就位。

红蓝对抗 Agent 可以紧随其后 —— *Ollama* 本地多模型并发是天然的实验场。

Z3 SMT 求解器集成是最具长期价值的投资, 但需要更充分的工程准备 (约束语言映射、增量求解器集成)。

总结

核心脉络

本手册从 LLM 与 Transformer 的理论脉络出发，经复盘 CodeBuddy 原生实践到系统设计与界面实现，完整阐述了约束式 AI 辅助编程系统的设计路径：

1. **LLM 与 Transformer**：从 Bengio 的神经语言模型 [Bengio et al., 2003] 到 Vaswani 的 Transformer [Vaswani, Shazeer, Parmar, et al., 2017]，从 Scaling Laws [Kaplan, McCandlish, Henighan, et al., 2020] 到 RLHF [Ouyang, Jeffrey Wu, Jiang, et al., 2022]，LLM 的能力边界已经清晰——**概率性是根本特征，确定性是根本缺失**。
2. **复盘**：一周 64 条审计日志揭示了 LLM Agent 的五大系统性缺陷。提示词优化有天花板 [Liu, Lin, Hewitt, et al., 2023]，必须引入外部约束。
3. **架构约束**：统一四层架构、API 字典分发、Railway 模式——架构是 LLM 的导航系统。
4. **编译器约束**：编译器是人类的精华——自然语言的形式化离散化工具 [Aho et al., 2006]。类型系统将模糊的 LLM 输出转化为确定性结果 [Pierce, 2002]。
5. **JCS 保护约束**：RPC Functor 理论是严格的确定性知识描述映射 [S. Chen, 2024]。LLM 在可形式化部分不应替代确定性方案。
6. **设计规范**：五层拦截器架构 + 提示词天花板认知——Dev Skill 实践证明了外部约束的必要性。
7. **实施方案**：F# 编译核心（L3 FCS 原生）+ TypeScript 周边层（L1/L2/L4/L5）+ AIO Avalonia 界面嵌入——语言选型遵循“原生能力匹配”原则，界面设计遵循“非侵入 + 信息透明”原则。

技术展望

1. **更强大的类型提取**: 用 AST 解析（而非正则表达式）提取类型信息，通过 FSharp.Compiler.Service 和 TypeScript Compiler API 实现
2. **多语言支持**: 扩展到 TypeScript、Rust 等强类型语言的编译反馈
3. **增量反馈**: 只发送新增错误（而非全部代码），减少 Token 使用
4. **学习型调整**: 根据历史数据学习最佳重试策略和模型选择
5. **约束形式化**: 将提示词规则逐步迁移到可执行的拦截器代码中，降低对 LLM 注意力的依赖
6. **AIO 深度整合**: Copilot 拦截器成为 AIO 桌面的内置服务——TypeSys 代码生成 + Copilot 编译检查 + API Builder 权限校验在同一界面中协同

LLM 的概率性是根本特征，确定性是根本缺失 [Brown, Mann, Ryder, et al., 2020; Vaswani, Shazeer, Parmar, et al., 2017]。

编译器不是 AI 的对手，而是人类形式化思维的巅峰 [Aho et al., 2006]——
AI 所欠缺的恰恰在此。

强类型不是限制 AI 的创造力，而是将 AI 的模糊输出
离散化为精确结果的桥梁 [Pierce, 2002]。

架构约束不是枷锁，而是为 LLM 提供可靠地图的导航系统。

Scaling Laws [Kaplan, McCandlish, Henighan, et al., 2020] 给了我们更大的模型——

编译器给出了**从不失忆的检查**。提示词优化有天花板 [Liu, Lin, Hewitt, et al., 2023]——编译器检查没有。

— 本手册的核心哲学

参考文献

- Achiam, Josh, Steven Adler, Sandhini Agarwal, et al. (2023). ?GPT-4 System Card.? In: *arXiv preprint arXiv:2303.08774*.
- Aho, Alfred V. et al. (2006). *Compilers: Principles, Techniques, and Tools*. 2nd ed. Addison-Wesley.
- Anthropic (2024). *Model Context Protocol Specification*. <https://modelcontextprotocol.io>.
- Austin, Jacob, Augustus Odena, Maxwell Nye, et al. (2021). ?Program Synthesis with Large Language Models.? In: *arXiv:2108.07732*.
- Bahdanau, Dzmitry, Kyunghyun Cho, and Yoshua Bengio (2015). ?Neural Machine Translation by Jointly Learning to Align and Translate.? In: *ICLR*.
- Bengio, Yoshua et al. (2003). ?A Neural Probabilistic Language Model.? In: *JMLR* 3, pp. 1137–1155.
- Brown, Tom B., Benjamin Mann, Nick Ryder, et al. (2020). ?Language Models are Few-Shot Learners.? In: *NeurIPS*.
- Chen, Mark, Jerry Tworek, Heewoo Jun, et al. (2021). ?Evaluating Large Language Models Trained on Code.? In: *arXiv preprint arXiv:2107.03374*.
- Chen, Siduo (2024). *RPC as a Functor: Cross-Platform Type Sharing*. DOI: 10.5281/zenodo.11398320.
- Cho, Kyunghyun, Bart van Merriënboer, Caglar Gulcehre, et al. (2014). ?Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation.? In: *EMNLP*.
- Chowdhery, Aakanksha, Sharan Narang, Jacob Devlin, et al. (2022). ?PaLM: Scaling Language Modeling with Pathways.? In: *arXiv:2204.02311*.

- Cousot, Patrick and Radhia Cousot (1977). ?Abstract Interpretation: A Unified Lattice Model for Static Analysis.? In: *POPL*.
- Dai, Zihang, Zhilin Yang, Yiming Yang, et al. (2019). ?Transformer-XL: Attentive Language Models Beyond a Fixed-Length Context.? In: *ACL*.
- Devlin, Jacob et al. (2019). ?BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.? In: *NAACL-HLT*.
- Hochreiter, Sepp and Jürgen Schmidhuber (1997). ?Long Short-Term Memory.? In: *Neural Computation* 9.8, pp. 1735–1780.
- Hoffmann, Jordan, Sebastian Borgeaud, Arthur Mensch, et al. (2022). ?Training Compute-Optimal Large Language Models.? In: *NeurIPS*.
- Kadavath, Saurav, Tom Conerly, Amanda Askell, et al. (2022). ?Language Models (Mostly) Know What They Know.? In: *arXiv:2207.05221*.
- Kaplan, Jared, Sam McCandlish, Tom Henighan, et al. (2020). ?Scaling Laws for Neural Language Models.? In: *arXiv preprint arXiv:2001.08361*.
- Lane, S. Mac (1971). *Categories for the Working Mathematician*. Springer.
- Li, Raymond, Loubna Ben Allal, et al. (2023). ?StarCoder: May the Source Be with You!? In: *arXiv preprint arXiv:2305.06161*.
- Liu, Nelson F., Kevin Lin, John Hewitt, et al. (2023). ?Lost in the Middle: How Language Models Use Long Contexts.? In: *arXiv preprint arXiv:2307.03172*.
- Mikolov, Tomas et al. (2013). ?Efficient Estimation of Word Representations in Vector Space.? In: *ICLR Workshop*.
- Moura, Leonardo de and Nikolaj Bjørner (2008). ?Z3: An Efficient SMT Solver.? In: *TACAS*.
- OpenAI (2023). ?GPT-4 Technical Report.? In: *arXiv preprint arXiv:2303.08774*.
- Ouyang, Long, Jeffrey Wu, Xu Jiang, et al. (2022). ?Training Language Models to Follow Instructions with Human Feedback.? In: *NeurIPS*.
- Pierce, Benjamin C. (2002). *Types and Programming Languages*. MIT Press.

- Radford, Alec, Karthik Narasimhan, et al. (2018). ?Improving Language Understanding by Generative Pre-Training.? In: *OpenAI*.
- Radford, Alec, Jeffrey Wu, Rewon Child, et al. (2019). ?Language Models are Unsupervised Multitask Learners.? In: *OpenAI Blog*.
- Raffel, Colin, Noam Shazeer, Adam Roberts, et al. (2020). ?Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer.? In: *JMLR*.
- Shinn, Noah, Beckett Labash, and Ashwin Gopinath (2023). ?Reflexion: Language Agents with Verbal Reinforcement Learning.? In: *NeurIPS*.
- Sutskever, Ilya, Oriol Vinyals, and Quoc V. Le (2014). ?Sequence to Sequence Learning with Neural Networks.? In: *NeurIPS*.
- Syme, Don, Adam Granicz, and Antonio Cisternino (2007). *Expert F#*. Apress.
- Touvron, Hugo, Thibaut Lavril, Gautier Izacard, et al. (2023). ?LLaMA: Open and Efficient Foundation Language Models.? In: *arXiv preprint arXiv:2302.13971*.
- Vaswani, Ashish, Noam Shazeer, Niki Parmar, et al. (2017). ?Attention Is All You Need.? In: *NeurIPS*.
- Wang, Zihan, Jiayuan Mao, Jason Wu, et al. (2023). ?Self-Refine: Iterative Refinement with Self-Feedback.? In: *NeurIPS*.
- Wei, Jason, Yi Tay, Rishi Bommasani, et al. (2022). ?Emergent Abilities of Large Language Models.? In: *TMLR*.
- Wei, Jason, Xuezhi Wang, Dale Schuurmans, et al. (2022). ?Chain-of-Thought Prompting Elicits Reasoning in Large Language Models.? In: *NeurIPS*.
- Wu, Qingyun, Gagan Bansal, Jieyu Zhang, et al. (2023). ?AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation.? In: *arXiv:2308.08155*.
- Yao, Shunyu, Dian Yu, et al. (2024). ?Tree of Thoughts: Deliberate Problem Solving with Large Language Models.? In: *NeurIPS*.
- Yao, Shunyu, Jeffrey Zhao, Dian Yu, et al. (2023). ?ReAct: Synergizing Reasoning and Acting in Language Models.? In: *ICLR*.